# 生成式人工智能引发高校网络意识形态风险：样态、诱因与纾解

路坤皓，郝文斌

(哈尔滨师范大学 马克思主义学院，黑龙江 哈尔滨 150025)

**摘　要**：生成式人工智能掀起的数字化浪潮，深刻影响高校网络意识形态建设。作为新兴技术样态，生成式人工智能技术不断内嵌渗透到高校网络场域当中，呈现出异化、操纵、解构和缺位等多重现实样态。在此前提下，资本失序、技术失控、内容失真和把关失灵等因素容易诱发高校网络意识形态风险，须以价值赋魂、技术向善、内容规范、制度供给为纾解策略，力求在防范高校网络意识形态风险的过程中，规训发展方向、扎紧伦理藩篱、筑牢防控屏障和完善约束体系。

**关键词**：生成式人工智能；高校；网络意识形态；意识形态风险

**中图分类号**：D920.0　　**文献标识码**：A　　**文章编号**：1672－4283(2025)04－0165－12

**收稿日期**：2025－01－15　　**DOI**：10.15983/j.cnki.sxss.2025.0712

**基金项目**：国家社会科学基金重点项目“信息时代高校意识形态安全风险预警研究”(21AKS009)

**作者简介**：路坤皓，哈尔滨师范大学马克思主义学院博士研究生；郝文斌，哈尔滨师范大学马克思主义学院教授，博士研究生导师。

生成式人工智能(Generative Artificial Intelligence)是一种基于大规模数据集和生成式算法，能够自主生成新的原创性内容(如文本、图像、音频、视频等)的模型和技术。作为人类社会发展进步的现实产物，在深刻改变人类日常生活、认知方式和行为模式的同时，生成式人工智能早已僭越出自身工具属性范畴，呈现出带有意识形态属性的样态表征，进而极有可能衍生出多重意识形态风险。尤为重要的是，高校作为意识形态工作的前沿阵地，面临来自网络场域的文化渗透层出不穷、从未停止。中国特色社会主义进入新时代，党中央高度重视识别和防范人工智能领域可能出现的意识形态风险。习近平指出：“要加强人工智能发展的潜在风险研判和防范，维护人民利益和国家安全，确保人工智能安全、可靠、可控。”[1]为此，正确审视生成式人工智能内在机理，深刻把握技术特征，科学透视内嵌风险，对于取得高校场域网络意识形态斗争胜利、推动高校意识形态阵地建设和掌握网络意识形态建设主导权具有重大现实意义。

## 一、高校网络意识形态风险的样态呈现

恩格斯指出:“任何意识形态一经产生,就同现有的观念材料相结合而发展起来,并对这些材料作进一步的加工。”[2]309随着生成式人工智能在高校中的广泛应用,潜藏的高校网络意识形态操纵风险不容忽视。在高校网络意识形态场域,生成式人工智能带来的意识形态风险呈现出异化、操纵、解构和缺位的现实样态。

(一)高校网络意识形态异化风险:资本合谋—政治内隐—认同失落

第一,资本技术合谋“数字风险”。在高校师生使用生成式人工智能的过程中,数字风险来源于技术纳入资本逻辑体系当中,形成资本技术合谋下的“数字风险”。其一,资本趋利操控技术方向。美国学者杰瑞·卡普兰指出:“最终,很多领域只剩下对信息的操纵,比如金融系统、教育机构以及娱乐媒体。”[3]44生成式人工智能的出现使得互联网巨头及华尔街垄断资本实现控制的模式进一步增强,在商业资本的深度把持和驱动下,通过生成式人工智能将数字资源转化为商业价值,不断挖掘数字资源中的剩余价值。人工智能主导的数据筛选与算法推荐,在信息推送时会研究高校学生群体的交互行为、爱好特征、兴趣轨迹等进行精准画像,高校学生群体由于年龄、爱好、习惯等大多相近相似,生成式人工智能会将拥有类似画像的高校学生群体归为同类群体,精准地定向输出某些内容,刻意固化群体思维,技术方向不断被资本操控。其二,技术霸权导致风险升级。生成式人工智能的使用者主要集中于高校学生群体。高校学生群体的技术使用需求量大、意愿性高、活跃性强,易于接受新思想、新事物,是生成式人工智能技术使用的主要受众群体,但他们对技术产品背后潜藏的意识形态危险欠缺判断力和识别力。而生成式人工智能正好迎合这一群体,在算法“协同过滤”的影响下,网络主流文化极易被拒斥在高校学生群体的视野之外,西方国家凭借技术霸权,实现不良社会思潮隐性传播,经由移动互联网终端对高校网络场域进行渗透,海量数据资源在技术霸权的裹挟下被内涵重释、逻辑重构、意义重组,引发高校网络意识形态风险。

第二,政治内隐暗含“隐性渗透”。生成式人工智能的技术蝶变和模式创新,加剧高校网络意识形态风险。其一,高校网络主流意识形态叙事体系频遭解构。生成式人工智能通过算法技术的编码与解码,将网络主流价值进行解构与重构,再利用海量数据资源将不同数据缝合拼接,布置隐匿西方政治意图、传递西方政治倾向、传播西方政治价值的“事实景观”。其二,高校网络主流话语表达易被肢解。生成式人工智能通过将高校师生长久以来所接受的宏大叙事“化整为零”,以颗粒化代替板块化、以碎片化代替线性化、以拼凑化代替整体化来实现话语表达的肢解,妄图造成主流话语缺场,非主流话语趁机进场。

第三,认同失落遮蔽“群体视野”。高校网络主流价值的“牵引力”不足,发轫于生成式人工智能难以在生成内容和现实边界之间实现灵活互动,高校学生群体视野被愈发遮蔽。其一,群体极化削弱主流价值引领。基于西方语言数据库的生成式人工智能大量充斥与主流价值相悖、偏见性、同质化的内容引发“信息偏食”,个体对集体的认知将趋于模糊,将高校学生群体困于“信息孤岛”之中,“中心”解构带来的“离心力”将助推群体极化趋势,削弱高校网络主流价值引领力。其二,人格虚拟致使现实空虚。在人机互动过程中,由于技术的迅速便捷,高校学生群体极易对真实自我妄自菲薄,而对虚拟自我大加赞赏,导致虚拟人格不断僭越现实人格,高校学生群体不断丧失主体价值判断,主体价值被逐渐让渡,从而对主流价值产生疏远感和排斥感。

（二）高校网络意识形态操纵风险：人机异化—技术崇拜—权力流散

第一，人机异化导致主客异位。一项基于某大学样本的研究显示，“超过七成的大学生（72.77%）表示熟悉生成式人工智能”“三分之二的大学生开始使用生成式人工智能的时间在 2022 年 12 月—2023 年 6 月间（67.05%）”，只有“小部分大学生表示没有使用过（6.47%）”。[4] 可见，生成式人工智能在高校应用较为普遍。大学生长期过度使用人机交互，容易导致个体判断力、自我感知力、主观能动力逐渐弱化乃至丧失。其一，高校学生隐私数据泄漏风险。生成式人工智能的运行基于充分了解高校学生需求，这要求高校学生卸下个人隐私防备，消除自身隐私壁垒，而生成式人工智能大模型无法做到对海量数据资源实现彻底清洗，而当无法及时发现和过滤违法信息或不良内容时，涉世未深的高校学生的个人隐私信息面临泄漏风险。其二，人际交往日益单向度化放大风险。马尔库塞指出：“当一个社会按照它自己的组织方式，似乎越来越能满足个人的需要时，独立思考、意志自由和政治反对权的基本的批判功能就逐渐被剥夺。”[5]3-4 高校学生网络群体沉溺于虚拟对话寻求价值认同，使现实社会交往更为疏离，容易导致思想观念与行为体验脱离。当身体“缺场”式的数字交往愈发代替现实空间的身体“在场”交往，会日益导致高校学生群体性孤独和丧失个体情感的现象出现。其三，人机交互造成人类主体“降格”。生成式人工智能具有多头注意力（Multi-Head Attention）技术，可以最大限度捕捉、理解并输出各式内容，一定程度上实现“自我训练”。这将使具有自主意识的生成式人工智能从“仆人”逐渐演化为“主人”，高校学生主体“降格”为技术附庸，从而颠倒了人机关系。

第二，技术崇拜导致风险忽视。马克思指出：“机器本身是人对自然力的胜利，而它的资本主义应用使人受自然力奴役。”[6]508 高校学生群体富有探索性，极易落入技术崇拜的陷阱，进而忽视潜藏风险。其一，生成式人工智能潜藏非法提问风险。当敏感词汇被去除后，生成式人工智能就不会将其列为非法提问。此类的技术漏洞一旦被利用，就会导致非法和有害内容大肆传播。其二，生成式人工智能潜藏认知偏差风险。由于生成式人工智能所生成的内容信息真假难辨，易被用于捏造大量社会负面虚假消息，当这些误导信息被精准推送到识别能力较弱、生活经验不足、信息渠道不多的高校学生时，容易对他们的思想观念、道德情操和价值选择产生消极影响。其三，生成式人工智能潜藏技术伦理风险。高等院校的根本任务是实现立德树人，而生成式人工智能在实际使用过程中则扮演了类似“高校教师”的角色。当前，高校学生传统知识获取来源愈发被网络来源所替代，而教师主体权威逐渐丧失，生成式人工智能集知识资源、搜索来源和内容生成于一体，在高校网络意识形态场域容易造成信息操纵、舆论把控、酝酿风险，致使全新的技术伦理风险出现。

第三，权力流散导致霸权进场。马克思认为，“科学对于劳动来说，表现为异己的、敌对的和统治的权力”[7]358。话语权是生成式人工智能赋权逻辑中的重要一环，而话语权高度流散更助推了风险产生。其一，场景变迁改变权力分布。生成式人工智能通过其对话场景，以人机交互的形式影响高校师生。不同场景下的数字信息流向高校网络场域发散传递，逐渐演变为具有高变动性的对话环境，对话场景不再仅仅受制于传统“把关人”。其二，语料势差限制权力增长。在生成式人工智能的语料库中，中文语料特别是符合主流意识形态的优质中文语料仍处于相对匮乏的现实境地。有数据显示，ChatGPT 的中文语料规模不足千分之一（0.099%），而英文语料规模则占比 92.65%[8]。中文语料相对匮乏的先天不足，可能导致生成式人工智能大模型迭代的后天乏力，在中文语料“缺场”的情况下，英文语料库中的驳杂数据不免被吸纳进来，限制高校网络主流话语的广泛传播。

（三）高校网络意识形态解构风险：算法监控—认知茧房—价值遮蔽

第一，算法监控使高校学生群体“一览无余”。随着大数据技术和人工智能技术的迅速普及，高校

学生群体被算法监控起来,其一举一动、一言一行均被记录、分析、追踪,都被以数据的形式描绘出“数据肖像”,个人隐私及数据被无限制爬取导致数据滥用,高校学生利用生成式人工智能提出的问题,深刻凸显着其情感倾向和价值取向,而这种个体表达会被生成式人工智能中内含的大模型所捕捉,进而通过内容生成的功能对高校学生进行价值渗透,凭借人机交互的形式对高校学生进行话语影响,依靠灵活功能的方式对高校学生进行潜在渗透;同时生成内容愈发接近群体价值预设,个性化推荐逐步进化为个性化定制,在群体喜好的基础上生成内容,拒斥异质信息,进一步加重了高校网络主流意识形态传播的现实障碍。

第二,认知茧房使高校学生群体“认知迷惑”。生成式人工智能的底层模型、算法机制、语料数据及大模型内部的复杂性等共同决定了其实质为“技术黑箱”。在算法推荐的功能加持下,算法规定的信息生成逻辑和生成路径逐步成为“信息茧房”,长期浸润高校学生群体的日常生活,进而导致风险产生。作为生成式人工智能内容文本的主观聚合表现,算法歧视具有明显的价值倾向。就内在机理而言,算法歧视遵循着大数据计算的功能特质,其运行必然会打上具有明显意识形态取向的价值烙印。就实践逻辑而言,算法歧视具有利己本性,只会推荐有利于自身特殊利益、带有歧视性的信息内容,而撇开与自身利益相悖的异质内容,构建“认知茧房”以迷惑和降低高校学生的思维能力和认知水平。而随着生成式人工智能技术的不断成熟以及数字资源的不断累积,高校学生的数字素养就愈发不足以批判性地审视生成内容的真伪,进一步影响高校学生的是非判断。

第三,价值遮蔽使高校学生群体“偏听偏信”。在使用生成式人工智能的过程中,高校学生群体会逐渐放松对内容信息的把关和甄别,继而减少关注主流媒体的时间。高校学生如若受到来自生成式人工智能产生的错误信息诱导,就会对自身原有的思想道德观念发生质疑。其一,“标签劫持”助推舆情极化。由于西方国家的生成式人工智能普遍带有特定的政治立场和价值偏向,一旦高校爆发重大舆论事件,生成式人工智能极有可能被恶意使用,以“标签劫持”的方式集中在某一或者多个议题集歪曲事实、煽动群体对立、制造虚假共识,以实现意识形态操控和颠覆主流价值的险恶目的。其二,“真相挖掘”争夺注意力资源。生成式人工智能较低的技术门槛容易造成虚假内容扩散传播。相对于以往的人工智能,生成式人工智能能够以更加仿真的形式来生成图片、视频,以更具多样性、真实性的素材来“自圆其说”,聚焦固定话题进行同质化的规模输出,以“纯路人”等伪装角色来主导高校网络场域议题,引导舆论走向。当无法保证正确率的虚假内容吸引高校学生的注意力时,会在真假难辨中造成真相层面的“注意力匮乏”,而在人机交互中导致错误信息的“注意力丰富”,影响高校网络意识形态安全。

(四)高校网络意识形态监管风险:监管迟滞—公意消弭—供给不足

第一,监管迟滞致使应对不及时。当前,生成式人工智能俨然已经成为一种数字权力,深刻凸显监管仍存在迟滞的严峻现实。其一,传播范式更新消解主导权。政治传播研究的奠基人之一哈罗德·拉斯韦尔所提出著名的“5W”传播理论认为,“说明传播行为有一个简便方法,就是回答下列问题:谁?说什么?通过什么渠道?向谁?有什么效果?”[9]199而如今,生成式人工智能俨然已经从媒介的身份发展为传播者,“实现了从工具性向主体性的跨越”[10]。生成式人工智能问询式的人机互动,属于私人化内容信息,信息范围处于恒定状态,整体过程不对外公开。但每次的对话信息将被记录并被应用,这种非公开的方式将导致异质信息难以察觉和捕捉,极易消解高校网络意识形态主导权。其二,技术样态多变延缓主动权的实施。生成式人工智能时常会迎合高校师生需求,提供多样化的用户选择,即高校师生在信息选择过程中对某一话题、内容、领域表现出浓厚兴趣时,生成式人工智能会以

兴趣为导向定制个性化内容，从而延长相关监管机制的研判时间和应对方式。

第二，公意消弭增大监管风险。生成式人工智能以全新的信息处理方式影响乃至侵蚀高校师生的意识形态体认，使群体认知逐渐趋于碎片化和无意识牵引。其一，大众碎片认知消弭正确公意。生成式人工智能善于将“宏观叙事”“完整论述”分割为“碎片叙事”“拼凑论述”。这不仅颠覆事件的完整框架，还会打碎高校学生固有的连贯思维方式，在思考、辨析、体察问题时呈现出前后割裂的碎片化特征，丧失独立思考能力，更容易随波逐流，消弭正确的网络公意。其二，无意识牵引削弱共同思想基础。随着生成式人工智能的应用场景叠加倍增，在人机互动过程中，生成式人工智能看似正常的回答背后实则为包含立场、观点及意识形态色彩的无意识牵引，而机器进化中所内含的不确定性更加助长了无意识牵引的泛化，造成高校网络主流文化作用力、引领力的削弱。

第三，供给不足致使引领削弱。囿于生成式人工智能的技术叠加，高校网络主流意识形态供给存在削弱风险。其一，主流思想内容供给有效性不足。高校学生群体具有多元需求和内容倾向，但主流思想内容的默认设置固化了供给效度，阻隔了内容持续供给。而生成式人工智能算法一致性的内容供给，也导致了主流思想内容供给的同一性与无差别性。其二，主流思想制度供给分众性不足。高校学生的多元化、层次化、动态化的意识形态需求愈发凸显，这种网络场域中意识形态的群体性下沉，在使高校学生群体多样需求得到满足的同时，也凸显出网络场域制度供给分众性不足的现实风险。现有制度供给，面对“网络猎奇”引发的网络狂欢对高校网络主流意识形态的离散分割尚显“分身乏术”。

## 二、高校网络意识形态风险的诱因探赜

生成式人工智能作为基于文本、图像、音频、视频、模型等的智能技术，其本身就具有意识形态属性承载作用，更在“人—机”互动过程中诱发意识形态风险。基于生成式人工智能的高校网络意识形态风险样态，应聚焦资本失序、技术失控、内容失真和把关失灵等维度进行缕析。

### （一）资本失序：生成式人工智能内嵌风险来源

托·约·邓宁（T. J. Dunning）指出：一旦有适当的利润，资本就胆大起来。[11]36资本逻辑贯穿于生成式人工智能的发展始终，成为生成式人工智能诱发高校网络意识形态风险的“策源地”。第一，生成式人工智能内含资本增殖逻辑。生成式人工智能的产生和发展主要依赖海量数据资源的反复投喂，而数据资源作为新型的资本形态，则主要被西方资本主义国家的互联网企业所把控和操纵。资本具有天然逐利性和空间扩张性，只有不断实现资本有效增殖，生成式人工智能背后的社交媒体平台才能不断获得相应利润。作为特定社会条件下的技术产物，生成式人工智能训练数据来源的庞杂性，导致其难以避免滋生出有害信息和不良言论。高校师生在日常使用过程中难免会接触到这些有害信息和不良言论，会严重影响他们的身心健康，高校网络空间秩序也会遭到实质破坏。在资本的趋利性驱使下，社交媒体平台通过操纵生成式人工智能来最大程度获取资本增殖效益，以数据资源掌控话语资源，以科技优势僭越主流权威，以精准数据投喂高校师生，潜移默化地输出西方“普世价值”，从而引发高校网络意识形态风险。

第二，生成式人工智能内隐资本政治逻辑。生成式人工智能主要基于互联网海量数据库和语料库，研发过程受到技术研发者政治倾向和政治立场的深刻影响，使其本身超越了中立性质的工具范畴，具有意识形态承载属性。而生成式人工智能不仅显现为智能数据技术的深度应用，还体现为西方国家进行意识形态输出的手段之一，成为西方国家渗透思维方式、价值观念、社会理念的技术渠道。与此同时，西方国家容易通过投喂“有毒”语料，批量生成虚假信息，配合“AI 水军”进行误导性引导和颠覆性宣传，使得高校网络意识形态风险更趋隐蔽激烈。

第三,生成式人工智能渗透资本文化逻辑。约翰·汤普森认为:“一日复一日,一周复一周,报纸、收音机和电视持续不断地传给我们……有关形象、信息和思想。”[12]174生成式人工智能发轫于西方国家,其底层逻辑、模型框架、技术迭代都难以完全隔绝西方文化背景的影响。高校师生在使用生成式人工智能时难免会受到其价值立场、价值预设、价值意图的影响。特别是在大规模预训练之后,生成式人工智能会大量吸纳大数据中的驳杂信息,加之中外文化差异的结构势差,生成式人工智能浓厚的西方意识形态色彩暴露无遗,对“网生一代”大学生的影响更为广泛。

(二)技术失控:生成式人工智能致使风险叠加

马克思指出:“矛盾和对抗不是从机器本身产生的,而是从机器的资本主义应用产生的。”[6]508数字时代,数据资源俨然已经成为一种“社会化技术权力”,成为可对人类社会经济、政治、文化进行控制和调动的支配性力量。生成式人工智能也不例外。在资本与技术的共谋之下,这种数据权力逐步滑向愈发失控的风险境地。

第一,“技术利维坦”诱发高校网络意识形态安全风险。马尔库塞认为:“在当代,技术的控制看来真正体现了有益于整个社会集团和社会利益的理性。”[5]10毋庸置疑,生成式人工智能所具有的思维逻辑和价值观念并非源自逻辑推演,而是经过大规模预训练之后的结果,其本质上仍是人类的思维逻辑和价值观念。其一,“算法偏见”侵蚀高校网络意识形态安全根基。基于信息协同过滤系统,算法推荐在高校网络意识形态领域精准投送隐含政治偏见、社会偏见、民族偏见等的“私人订制”式内容。例如,在与 ChatGPT 或 NewBing 等生成式人工智能互动时,在问及美国与伊拉克战争时,生成式人工智能的回答明显赞许美军的“解放自由”行动,而对伊拉克当局的抵抗持负面态度,这对历史知识储备相对不足的部分高校学生无疑会产生错误引导。生成式人工智能所固有及产生的算法偏见和舆论操控,容易引发对网络主流文化的质疑,造成高校学生思想观念的混乱和价值观念的扭曲。其二,“数字鸿沟”挤压高校网络意识形态安全空间。生成式人工智能在意识形态立场方面的“先天不足”若直接作用于高校学生,势必造成一定程度的思想操纵和宰制,使高校学生群体蒙蔽于西方意识形态的诱骗性话术中,削弱这一群体的政党、国家和社会认同感,造成社会主义主流意识形态的合法化危机。高校学生因“信息茧房”只能收到符合资本利益好恶的“美好愿景”,而不能接受符合社会主义主流意识形态的精神文化产品,一道“数字鸿沟”将高校网络意识形态安全空间割裂开来。

第二,“技术依赖”诱发高校网络意识形态安全风险。生成式人工智能为高校学生网络群体带来“便捷化”的体验,因“使用与满足”效应产生的智能依赖和价值归属易造成人的主体性让渡,削弱高校学生群体对深刻或重大问题的体悟程度,呈现价值判断真空状态,导致主体性在“信息投喂”和信息“选择性加工”等隐形控制中逐渐消解;同时,沉溺于技术所带来的便利之中,导致现实之中人与人的交往更加匮乏,逐步生成一种身体缺场的“电子人格”,使得“电子人格”愈发具有主体性的存在意义,压缩了高校师生之间情感沟通的行动领域,加剧了高校师生之间的信任危机,使高校教师立德树人的角色逐渐边缘为“旁观者”,进而架空高校网络意识形态的群众基础。

(三)内容失真:生成式人工智能助推风险裂变

马克思、恩格斯指出,资产阶级“赋予自己的思想以普遍性的形式,把它们描绘成唯一合乎理性的、有普遍意义的思想”[13]552。生成式人工智能通过真实与虚假杂糅、真相与谣言互掺、撕裂与劣质同构来助推高校网络风险,给网络意识形态安全带来潜在风险挑战。第一,真实与虚假杂糅助推高校网络意识形态风险。在资本和技术的合谋下,生成式人工智能会生成错误甚至伪造内容。囿于生成式人工智能大模型技术的不成熟,又称“技术幻觉”,导致其会自动生成本质错误但形式正确的信息内

容，错误引导认知走向，混淆智能生成与人类创造，特别是当其深度伪造校园周边、公众人物、政治领域等话题时，极易影响高校学生正常的认识思维，扰乱高校网络舆论氛围，引发高校网络舆情事件，以虚假信息挑起非理性的“情感共鸣”，进而煽动群体对立，促使“群体极化”情绪发酵，分化凝聚共识，使高校学生群体真假难辨，导致出现“眼见不一定为实”“耳听不一定为虚”的离散舆论生态和真假互糅的文化景观。第二，真相与谣言互掺助推高校网络意识形态风险。为了实现利益最大化，生成式人工智能会按照资本逻辑和价值体系来规约高校学生群体。例如，由 ChatGPT 所捏造的高校教授性骚扰事件，就深刻凸显出生成式人工智能信息来源可信度方面的潜在风险。在既已形成的资本与技术互嵌的意识形态景观下，生成式人工智能利用几近同质化、智能化的谣言信息来虚构历史和编造谎言，误导高校学生群体的价值认同和思维认知，破坏中国国家形象，销蚀主流意识形态的权威性和主导性，使高校网络意识形态风险愈发隐蔽化、复杂化、难觅化。第三，撕裂与劣质同构助推高校网络意识形态风险。由于生成式人工智能为了更好回应高校学生需求，会将互联网中承载着价值判断和意识形态倾向的海量信息进行吸收，其中不乏包含种族歧视、民族分裂和群体对立等偏见性质信息，经过模仿式、缝合式加工后以“公平客观”的面目示人，通过网络传播输出偏见信息，造成高校学生群体思维窄化和情绪对立。此外，源于生成式人工智能复制便捷等特点，带有内隐和契合资本主义意识形态的所谓“学习资料”或“学术文章”大量生成，传统高校思想政治教育的完整传播链条被肢解，教育内容的不确定性增加，劣质内容恣意扩散，逐渐稀释高校网络主流文化的主导性和权威性。

（四）把关失灵：生成式人工智能导致风险升级

列宁指出：“工人本来也不可能有社会民主主义的意识。这种意识只能从外面灌输进去”[14]29。但哪种意识和信息能够通过筛选，就成为意识形态把关的必要步骤。“把关人”理论的提出者卢因指出：“信息总是沿着包含有‘门区’的某些渠道流动，在那里，或者根据公正无私的规定，或者根据‘守门人’的个人意见，就信息或商品是否可被允许进入渠道或继续在渠道里流动作出决定。”[15]134“把关人”理论实质上是社会流动信息控制理论，聚焦于只有经过“把关人”的审查和筛选的意识形态和信息内容才能进入社会传播场域。传统媒体时代，传统“把关人”一般由经过专业训练、具有专业素养的专业人员担任。生成式人工智能背景下把关制度关口出现了位移，“智能算法”等逐渐演变为新型“把关人”。第一，生成式人工智能体高度仿真致使传统把关失灵。负载着西方意识形态的生成式人工智能通过深度伪装渗透高校网络传播场域，在资本逻辑和技术霸权的合谋操纵下，可以轻易实现左右高校舆论场议题、掩盖事实真相、挑拨对立情绪等恶意目标，突破把关防线。第二，生成式人工智能内容高度仿真致使传统把关失灵。长久以来，传统“把关人”会基于自身的专业训练和专业素养对信息内容进行价值判断和分析把关，而如今大量经数据加工过的信息内容以碎片化、缝合化、重组化的呈现形式颠覆了传统“把关人”知识背景、认知范围、思维模式，真假难辨的合成内容高度耦合，令传统“把关人”无法正确分辨涉及高校网络场域信息内容的真实与否。正如有学者指出：“在很短的时间内，ChatGPT 已经迅速平台化，俨然成为一个未来人们绝大部分信息与行动的超级把关人。”[16]第三，生成式人工智能算法黑箱难题致使传统把关失灵。传统把关时代，“把关人”会通过把关效果来动态掌握和调整把关机制。但生成式人工智能算法黑箱导致其运作机理、运作节点、运作规律都难以捉摸，导致“把关人”更加难以获得准确把关效果反馈。

## 三、高校网络意识形态风险的纾解策略

党的二十届三中全会作出了“完善生成式人工智能发展和管理机制”[17]34的重要部署，为加强生

成式人工智能管理、有效防范化解其发展带来的意识形态安全风险提供制度保证。面对生成式人工智能背景下高校网络意识形态面临的新风险、新样态,必须立足实践,因势利导,加强思想价值引领,更好理清高校网络意识形态理路方向;实现技术向善,以完善的技术生态扎紧高校网络意识形态伦理藩篱;着力规范内容,以生成内容审查筑牢高校网络意识形态防控屏障;推动制度供给,以加强制度建设完善高校网络意识形态约束体系,才能更好应对高校网络意识形态风险,更好维护党和国家网络意识形态安全。

(一) 方向引领: 明晰高校网络意识形态建设发展理路

习近平指出:“在坚持马克思主义指导地位这一根本问题上,我们必须坚定不移,任何时候任何情况下都不能有丝毫动摇。”[18]33 当前,面对生成式人工智能可能带来的高校网络意识形态风险,应坚持马克思主义指导地位,广泛践行社会主义核心价值观,牢牢掌握网络意识形态领导权。第一,坚持和巩固马克思主义在高校网络意识形态领域的指导地位。马克思、恩格斯认为:“共产党一分钟也不忽略教育工人尽可能明确地意识到资产阶级和无产阶级的敌对的对立。”[19]66 在生成式人工智能的迅猛发展背景下,面对真实与虚假杂糅、真相与谣言互掺、撕裂与劣质同构的数字狂潮,要保障高校网络场域生成式人工智能的正确发展方向,就必须坚持马克思主义立场、观点和方法,坚持网络主流文化的引领作用,既实现对网络场域宏大叙事的政治引领,又凸显对现实场域舆论生态的诉求观照,以价值理性引领工具理性,化解网络意识形态渗透,凝聚高校师生思想共识;同时,高校应当“推动思想政治理论课改革创新,不断增强思政课的思想性、理论性和亲和力、针对性”[20],夯实高校意识形态教育主阵地。高校学生正处于自我认知逐渐走向成熟的“拔节育穗期”,更要强化高校学生社会实践教育环节,不断增强高校学生对基本国情的认识和了解,不断增强马克思主义中国化最新理论成果的说服力,让高校学生在实践中体悟中国共产党领导人民取得的辉煌成就,在实践中感受中国式现代化道路的历史意义和时代价值,是科学应对生成式人工智能网络意识形态风险的重要方式。第二,坚持以社会主义核心价值观引领高校网络意识形态安全建设。习近平指出:要“更加重视运用人工智能、互联网、大数据等现代信息技术手段提升治理能力和治理现代化水平”[21]115。在数据资源俨然成为新兴权力的价值前提下,生成式人工智能的开发与运用必须内嵌和植入社会主义核心价值观,以保证生成式人工智能的价值正当性。以社会主义核心价值观为引领,就可以最大限度地保障生成式人工智能观点表达的正面属性、立场观念的正确表达、道德观念的正确传播、数字具象的正向传达,使生成式人工智能转化为巩固高校网络意识形态安全建设的“最大增量”。第三,坚持以主流意识形态引领高校网络场域智能应用场景向善发展。有学者指出:“随着算法与技术的发展,类 ChatGPT 的生成式人工智能已具有高度自组织性和自适应性,不仅参与构造传播过程,同时也能作为主动的传播者。”[22] 生成式人工智能作为高校网络意识形态的斗争新场域,其智能应用场景背后所体现的价值逻辑、技术规则与话语边界贯穿于高校学生人机交互的始终。随着生成式人工智能的进一步发展,其智能应用场景逐渐呈现出价值观念多样化、主体诉求多元化、群体区分间隔化的发展趋势。鉴于此,生成式人工智能的企业应坚持正确的舆论导向,引导高校网络场域智能应用场景,以数据人民性、对话针对性、内容思想性为指向,充实大模型训练语料的优质内容,拓展高质量语料库的丰富性,强化高质量语料库的建设,改变生成式人工智能内容生产的无序性,杜绝生成式人工智能信息内容的交互异化,实现对不同应用场景的差异化、分众化、层级化的分析研判。

(二) 技术向善: 以完善技术生态扎紧高校网络意识形态伦理藩篱

习近平指出:“新一代人工智能是依靠数据和知识‘双轮驱动’的,数据越多才能越智能。我们要

充分利用这些优势，推动新一代人工智能发展。”[23]121技术的问题终归要靠技术来解决。只有实现技术进步、提升技术实力、完善技术生态，才能更好地防范高校网络意识形态风险。第一，生成式人工智能企业要将技术向善贯穿于研发设计全过程。面对人工智能技术的兴起，人们通常认为“知道‘是什么’就够了，没必要知道‘为什么’……我们不必非得知道现象背后的原因，而是要让数据自己‘发声’”[24]67。就技术研发设计而言，生成式人工智能企业必须强调技术向善，落实“机器学习 + 人工标注”规范要求，加强科技伦理建设，落实平台企业主体责任。生成式人工智能平台作为网络空间的重要承载和桥梁纽带，是高校师生群体获取信息和认知、领略文化的重要渠道之一，同时还是网络内容的审查与管理的重要责任主体，这就要求生成式人工智能平台遵循符合科技伦理的通用规范、准则与标准。其一，要确保涉校生成式人工智能的人机交互过程具备足够的透明度，应将收集数据的情况告知高校师生，遵守“知情同意”原则，依法按照技术所需进行最小范围的涉校数据收集，将数据收集范围、收集目标和使用边界提前告知高校师生，酌情提供数据说明、系统性能及其他相关信息，使有关部门和高校师生能够正确理解和适当使用。其二，要兼顾社会效益和经济效益，正确认识并使用符合我国社会主流意识形态的高质量预训练数据，以数据的敏感程度、规模体量、安全级别为依据，对数据进行适当分类、设置数据生命周期，避免数据违规利用、过度收集和不当泄露，进行合法化、合规化、合理化吸收和筛选。其三，要重视技术研发人员的科技伦理建设，按照“科技创新，伦理先行”的要求，引导技术研发人员树立道德自觉和法律思维，使他们的正向价值转化为技术语言，实现生成式人工智能研发设计的技术向善。就技术研发自主而言，要强调技术为要，核心技术必须掌握在自己手中。第二，生成式人工智能企业要持续进行技术优化升级。习近平强调：“努力在人工智能发展方向和理论、方法、工具、系统等方面取得变革性、颠覆性突破，确保我国在人工智能这个重要领域的理论研究走在前面、关键核心技术占领制高点。”[1]关键核心技术不能受制于人，亟须技术加快升级发展。面对国际技术前沿领域深刻变革，立足经济高质量发展的现实需求，就要加快实现技术优化升级。由于生成式人工智能实际奉行“价值非中立”原则，这就迫切要求我国生成式人工智能企业集中人力、物力和财力对生成式人工智能领域的研究予以大力支持，加大网络主流意识形态数据“喂养”频次和力度，坚持技管结合理念，积极主动设置相关议题，实现高校网络空间主流意识形态的精准化和分众化传播，推动生成式人工智能的应用转化，逐渐打破资本对技术的操纵与控制；同时，生成式人工智能企业要通过争取国家政策支持、加大资金投入和科研项目揭榜挂帅等方式和形式来促进技术研发与转化，加快对信息加密技术、信息识别检测技术等的研发，以“数据正义”引领“算法正义”，推动形成以技术升级制衡技术霸权、以技术升级刺破技术壁垒、以技术升级跨越数字鸿沟，力争解决关键技术受制于人等“卡脖子”问题。

（三）内容规范：以生成内容审查筑牢高校网络意识形态防控屏障

曼纽尔·卡斯特提出：“作为一种历史趋势，信息时代的支配性功能与过程日益以网络组织起来。网络建构了我们社会的新社会形态，而网络化逻辑的扩散实质地改变了生产、经验、权力与文化过程中的操作和结果。”[25]569面对生成式人工智能可能给高校网络意识形态带来的风险挑战，我们需要从内容生成、内容鉴别和内容传播等方面，对生成内容进行更为严格的审核与规范。第一，要在生成式人工智能的内容生成上下功夫。歌德提出：“理论全是灰色，敬爱的朋友，生命的金树才是长青。”[26]77生成式人工智能内容生成的质量高低与数据文本压缩和还原具有高度相关关系，其内容生成要基于数据信息的复刻与重组。基于此，宣传、网信等有关部门应以保证采集信息的真实性、正确性、完整性为首要前提，通过不断地对输入信息进行真伪筛选和真假辨别，以实现内容还原阶段的质量把关。第

二,要在生成式人工智能的内容鉴别上“有眼力”。在西方国家占据技术优势、实行数字霸权垄断的现实前提下,生成内容中所具有的意识形态倾向导致风险暗藏。高校要着力提升大学生对生成内容的甄别能力,将数据模型、算法规则、技术语言等相关知识推送给学生,提升其对于生成式人工智能的局限认知,规避“理性致瘾”现象的发生。要积极引导大学生在人机交互中对生成内容保持理性辨别,将符合社会主义意识形态逻辑的正确信息输入预训练数据库中,优化通用大模型的数据集,防止“数据投毒”“模型投毒”,在技术可行的前提下,应确保生成式人工智能可检测系人为生成或操纵,使大学生能够以判断准确、真实客观、科学全面地甄别大量生成内容,形成抵御虚假信息侵袭的“群体防线”。第三,要在生成式人工智能的内容传播上做文章。哈罗德·伊尼斯指出:“一种媒介经过长期使用之后,可能会在一定程度上决定它传播的知识的特征。”[27]28宣传、网信等有关部门要通过生成式人工智能查明虚假内容及其传播主体,在主题模型的助力下,对虚假信息进行剖析、定位与清除,对冲突或悖于社会主流意识形态的错误信息、虚假信息、伪造信息进行根除,对存在风险的算法模块进行审查,构建生成式人工智能的交互式治理生态,实现高校师生与生成式人工智能的良性交互,以此来规制虚假信息的智能泛化和现实泛在,确保生成式人工智能始终处于内容真实可信的底线之内。

(四)制度供给:以加强制度建设完善高校网络意识形态约束体系

美国学者杰克·奈特指出:“制度影响了策略选择,并因而影响了社会结果。”[28]51制度作为规范化的结构规则体系,规约着高校网络意识形态建设的运行边界。健全的制度供给是实现高校网络意识形态建设的重要支撑。第一,要完善相关政策措施。习近平强调:“加快数字经济、互联网金融、人工智能、大数据、云计算等领域立法步伐,努力健全国家治理急需、满足人民日益增长的美好生活需要必备的法律制度。”[29]570严格合理的法律法规政策能够为生成式人工智能的发展框定行为规范边界,提供人机互动约束,圈定技术拓展红线。随着生成式人工智能的快速发展,2022 年,中华人民共和国国家互联网信息办公室等部门正式施行《互联网信息服务算法推荐管理规定》,明确提出对具有舆论性质的算法进行登记备案。2023 年 7 月,中华人民共和国国家互联网信息办公室等部门联合颁布了《生成式人工智能服务管理暂行办法》,为生成式人工智能指明发展方向和划定运行红线,实现了生成式人工智能在政策层面的有法可依、有据可查。2024 年 3 月,欧洲议会通过世界首部《人工智能法案》(Artificial Intelligence Act),明确提出要“创建符合欧盟价值观的人工智能系统”[30],并对特定人工智能实践的禁止及高风险人工智能系统作出具体要求。面对新情况、新境遇,法律法规政策的完善通常具有迟滞性。国家主管部门应立足技术发展,完善相关政策规定,把生成式人工智能与高校网络意识形态建设的规律相结合,保证生成式人工智能所带来的意识形态风险动态性与相关监管静态性之间的适度张力。相关部门和平台企业要严把入口关,严格把握准入机制,严格审查网络账号的申请,明确涉及生成式人工智能技术的适用范围;严格落实网络实名制,并对现有涉及的高校有关账号进行常态化摸底管理和动态化审核监管;以国家力量推动国有大模型的规模发展,以国家标准确立生成式人工智能的责任范围、基本原则和评价体系等,进而厘清各部门的权责职能和监管边界,强化协同监管;与此同时,要加强生成式人工智能中的人文关怀,留存“人工对话”机制,加快构建涉及高校的生成式人工智能治理细则,明确技术研发、生产和使用的相应法律责任,实现事前事中事后的内部纠正、溯源治理和精准归责,以充分保障涉及高校生成式人工智能产品的合法合规。第二,要优化制度机制建设。习近平明确指出:“要推动依法管网、依法办网、依法上网,确保互联网在法治轨道上健康运行。”[21]309其一,要优化以危机干预为指向的风险预警机制。正如有学者指出:“问题的正确打开方式是:我们如何为生成式 AI 这类大模型植入价值观,如何为像抖音这样的极易产生沉浸感的智能产

品加入干预和提醒机制。”[31]一方面，就风险源头预防而言，高校要提前进行风险研判，制定涉高校风险应急处置预案，对风险进行全面筛查、精准识别、科学分级分类，正确把握高校网络意识形态风险的呈现样态，使有关部门和高校师生能够准确辨别风险点所在，做到防患于未然；另一方面，就过程把控而言，高校要对风险传播的过程进行分阶段审查和监管，对不良话语信息或异质性话语信息进行严格把控，实现全过程风险预警。其二，要健全以舆情应对为导向的风险处理机制。高校要基于生成式人工智能的技术特点，将大数据识别技术嵌入高校网络意识形态的生产、传播、作用的全链条中，对风险数据进行智能辨别、智能锁定和智能过滤，精准把控高校网络舆情事件的现实走向和热点流向，对风险等级和性质进行科学分级分类及风险评估，提前谋划、因地制宜、立即部署相应措施，力争最大程度遏制高校网络舆情风险蔓延。其三，要优化以素养提升为指向的反训防范机制。古斯塔夫·勒庞认为：“群体永远漫游在无意识的领地，会随时听命于一切暗示，表现出对理性的影响无动于衷的生物所特有的激情，它们失去了一切批判能力，除了极端轻信外再无别的可能。”[32]28针对生成式人工智能在人机互动过程中容易造成智能反训，高校应向广大师生广泛普及生成式人工智能知识，提升对数据资源的认知，理解算法模型的运行逻辑，了解生成式人工智能的作用机理，以科学批判思维看待交互方式和技术局限性，着力提升高校师生在网络智能交互过程中的主体意识，树立正确的智能技术观念，避免步入技术崇拜的误区，在充分的人机交互中逐步养成符合人工智能的思维方式和行为习惯，以更好地应对人机交互过程中潜在的高校网络意识形态风险。

## [参　考　文　献]


[1] 习近平在中共中央政治局第九次集体学习时强调 加强领导做好规划明确任务夯实基础　推动我国新一代人工智能健康发展[N]. 人民日报，2018－11－01(1).

[2] 马克思恩格斯文集：第 4 卷[M]. 北京：人民出版社，2009.

[3] 杰瑞·卡普兰. 人工智能时代：人机共生下财富、工作与思维的大未来[M]. 李盼，译. 杭州：浙江人民出版社，2016.

[4] 李艳，许洁，贾程媛，等. 大学生生成式人工智能应用现状与思考——基于浙江大学的调查[J]. 开放教育研究，2024(1).

[5] 赫伯特·马尔库塞. 单向度的人：发达工业社会意识形态研究[M]. 刘继，译. 上海：上海译文出版社，2006.

[6] 马克思恩格斯文集：第 5 卷[M]. 北京：人民出版社，2009.

[7] 马克思恩格斯文集：第 8 卷[M]. 北京：人民出版社，2009.

[8] Gpt－3 Dataset Statistics[EB/OL]. OpenAl，2020－06－02. https：//github. com/openai/gtp－3/blame/master/dataset_statistics/languages_by_word_count. csv.

[9] 张国良. 20 世纪传播学经典文本[M]. 上海：复旦大学出版社，2003.

[10] 陈刚. 生成式人工智能驱动下的传播变革与发展研究：以 ChatGPT 为例[J]. 学术界，2024(6).

[11] T J DUNNING. Trades’ Unions and Strikes：Their Philosopher and Intention[M]. London：Forgotten Books，2016.

[12] 约翰·B. 汤普森. 意识形态与现代文化[M]. 高钰，等译. 南京：译林出版社，2019.

[13] 马克思恩格斯文集：第 1 卷[M]. 北京：人民出版社，2009.

[14] 列宁全集：第 6 卷[M]. 北京：人民出版社，2013.

[15] 丹尼斯·麦奎尔，斯文·温德尔. 大众传播模式论[M]. 祝建华，武伟，译. 上海：上海译文出版社，1987.

[16] 刘海龙，连晓东. 新常人统治的来临：ChatGPT 与传播研究[J]. 新闻记者，2023(6).

[17] 中共中央关于进一步全面深化改革 推进中国式现代化的决定[M]. 北京：人民出版社，2024.

[18] 习近平谈治国理政：第 2 卷[M]. 北京：外文出版社，2017.

[19] 马克思恩格斯文集：第 2 卷[M]. 北京：人民出版社，2009.

[20] 习近平. 思政课是落实立德树人根本任务的关键课程[J]. 求是,2020(17).
[21] 习近平谈治国理政:第 3 卷[M]. 北京:外文出版社,2020.
[22] 刘德寰,朱琦. 颠覆与重塑:下一代人工智能的传播学意义[J]. 新闻爱好者,2023(9).
[23] 习近平关于网络强国论述摘编[M]. 北京:中央文献出版社,2021.
[24] 维克托·迈尔-舍恩伯格,肯尼思·库克耶. 大数据时代:生活、工作与思维的大变革[M]. 盛杨燕,周涛,译. 杭州:浙江人民出版社,2013.
[25] 曼纽尔·卡斯特. 网络社会的崛起[M]. 夏铸九,等译. 北京:社会科学文献出版社,2001.
[26] 歌德. 浮士德[M]. 钱春绮,译. 上海:上海译文出版社,2011.
[27] 哈罗德·伊尼斯. 传播的偏向[M]. 何道宽,译. 北京:中国人民大学出版社,2003.
[28] 杰克·奈特. 制度与社会冲突[M]. 周伟林,译. 上海:上海人民出版社,2009.
[29] 习近平著作选读:第 2 卷[M]. 北京:人民出版社,2023.
[30] Artificial Intelligence Act[EB/OL]. European Parliament,2024-03-13. https://www.europarl.europa.eu/do-ceo/document/TA-9-2024-0138_EN.html.
[31] 喻国明. 关于生成式 AI 的发展与传播领域革命的若干思考——2023 年以来我的新传播研究:论点与框架[J]. 新闻爱好者,2024(5).
[32] 古斯塔夫·勒庞. 乌合之众——大众心理研究[M]. 冯克利,译. 北京:中央编译出版社,2000.

[责任编辑 杨 军]

# Generative Artificial Intelligence Causes Network Ideological Risk in Colleges and Universities: Pattern Presentation, Incentive Detection and Mitigation Strategies

LU Kun-hao, HAO Wen-bin

**Abstract**: The digital wave set off by generative artificial intelligence has a profound impact on the construction of university network ideology. As an emerging technology pattern, generative artificial intelligence technology is constantly embedded into the university network field, and its reality pattern presents multiple scenes such as alienation, manipulation, deconstruction and absence. Under this premise, factors such as capital disorder, technology runaway, content distortion and gatekeeping failure are easy to induce the network ideological risk in colleges and universities. It is necessary to take value invigorating, technology improving, content standardization and system supply as mitigation strategies, and strive to regulate the development direction, tighten ethical barriers, build a solid prevention and control barrier and improve the constraint system in the process of preventing the network ideological risk in colleges and universities.

**Key Words**: generative artificial intelligence; colleges and universities; network ideology; ideological risk