【马克思主义与当代中国】

生成式人工智能意识形态风险的生成及其防控

李 津[1],徐晓风[2]

(1.海南师范大学 马克思主义学院,海南 海口 570100;
2.哈尔滨师范大学 马克思主义学院,黑龙江 哈尔滨 150025)

摘 要:生成式人工智能实现了从判断式到生成式的技术范式跃迁,信息生产权从人类主体向智能算法部分让渡,推动意识形态生产、传播与斗争逻辑发生重大变革。生成式人工智能的意识形态属性贯穿技术全生命周期,表现为数据训练阶段无意识地内化既有社会结构性偏见,模型开发环节通过安全对齐机制实现特定价值观的有意识编码,内容输出层面持续再生产符合主导权力结构的符号暴力。技术对社会存在的系统性重构引发意识结构异化,全球科技权力结构性失衡催生新型意识形态霸权博弈,创新迭代与治理演进的断层开辟风险滋生空间,这三重因素是导致生成式人工智能意识形态风险的重要原因。对此,应营造韧性包容的环境生态、锻造自主可控的技术基座、构建智慧响应的能力中枢、厚植凝心铸魂的价值根基,从而系统构建生成式人工智能意识形态风险防控体系,为党牢牢掌握数字时代意识形态工作领导权、维护总体国家安全提供理论参考与实践路径。

关键词:生成式人工智能;意识形态;风险防控

中图分类号:G641 **文献标志码**:A **文章编号**:1674-5310(2026)05-0047-11

DOI:10.16061/j.cnki.cn46-1076/c.2026.05.006

随着ChatGPT、Sora等大模型的问世,人工智能技术完成了从判断式到生成式的范式跃迁,全方位驱动生产方式、传播方式与社会结构发生深刻变革。相较于传统人工智能仅能完成分类、识别、预测等判断型任务,生成式人工智能的突破在于具备了自主生成文本、图像、音频、视频等多模态内容的能力,能够替代人类完成大量信息生产与内容创作工作。这使得信息生产权从人类主体向智能算法部分让渡。算法不再是被动服务于人类创作的辅助工具,转而成为能够独立输出内容、影响公众认知的能动主体。信息生产权力的转移,直接推动意识形态领域的权力结构发生重组,意识形态的生产、传播与斗争逻辑都随之发生根本性改变。习近平总书记强调:“意识形态工作是为国家立心、为民族立魂的工作。”[1]意识形态安全是总体国家安全的重要组成部分。生成式人工智能的兴起,直接引发了意识形态斗争场域的转场,即从传统的报刊、电视逐步延伸至算法架构与数据流之中,算法规则本身成为意识形态博弈的核心场域。

需要明确的是,生成式人工智能既不是价值中立的技术容器,也不是完全受人类支配的被动工具,其底层技术逻辑从诞生之初就内嵌着特定开发主体的价值偏好,是数字时代意识形态的新型载体。正如习近平总书记所强调的:“古往今来,很多技术都是‘双刃剑’,一方面可以造福社会、造福人民,另一方面也可以被一些人用来损害社会公共利益和民众利益。”[2]202技术本身的双重属性,叠加生成式人工智能对意识形态领域的深刻影响,决定了开展生成式人工智能意识形态风险研究的现实紧迫性。当前,世界面临百年未有之大变局,全球意识形态斗争日趋激烈,西方敌对势力长期借助数字技术对我国

基金项目:海南省高等学校科学研究项目“生成式人工智能的意识形态风险防控体系构建研究”(Hnky2026-19)
收稿日期:2026-08-24

作者简介:李津(1989—),女,湖北武汉人,法学博士,海南师范大学马克思主义学院讲师,硕士生导师,主要从事思想政治教育研究;徐晓风(1956—),男,黑龙江木兰人,历史学博士,哈尔滨师范大学马克思主义学院教授,博士生导师,主要从事马克思主义基本原理研究。

开展意识形态渗透,生成式人工智能的普及为其价值观输出提供了新的隐蔽渠道。在此背景下,深入揭示生成式人工智能意识形态风险的生成机理,探索适配中国国情的生成式人工智能风险防控策略,对于党牢牢掌握意识形态工作领导权、维护总体国家安全、营造风清气正的网络发展环境与良好生态,都具有至关重要的理论和现实意义。

一、意识形态的理论内涵与生成式人工智能的意识形态属性

当前,学界关于生成式人工智能意识形态属性的讨论,长期被技术工具主义的主导框架所束缚。该理论的核心主张是,生成式人工智能本质上是价值中立的技术工具,其输出内容所呈现出的意识形态倾向,完全是使用主体赋予的,并非技术本身的内在属性。这种观点遮蔽了生成式人工智能的技术本质,也忽视了意识形态对技术架构的嵌入过程。要科学回答生成式人工智能何以具有意识形态属性,首先需要在理论上厘清意识形态的内涵,并揭示技术作为意识形态物质载体的内在机制。

(一)意识形态的内涵:从马克思恩格斯到阿尔都塞

在马克思恩格斯的经典论述中,意识形态首先被理解为颠倒的社会意识形式。马克思恩格斯提出:“统治阶级的思想在每一时代都是占统治地位的思想。”[3]意识形态不过是从上层落下的观念体系,它把特定阶级的特殊利益装扮成普遍利益,把历史形成的社会关系永恒化为自然秩序。这并非纯粹的认识论错误,而是根植于物质生产过程中的权力关系,即统治阶级占有生产资料的同时,也占有精神生产资料,从而能够向社会输出维护自身统治合法性的意义系统。恩格斯后来将其称为“虚假意识”,他强调意识形态通过对现实关系的遮蔽,使被统治阶级安于既有秩序。马克思在《资本论》中对商品拜物教的分析进一步表明,意识形态不仅可以体现为观念,而且可以凝结为物与物之间的关系本身,人对人的支配关系被颠倒为物对物的交换关系,并被人们当作自然事实加以接受。阿尔都塞在20世纪60年代重新激活了意识形态理论,并将其推向物质实践维度。他提出,“意识形态是个人与其实在生存条件的想象关系的‘表述’”[4]352;“意识形态把个人传唤为主体”[4]361,询唤的成功不需要暴力强制,而是让被询唤者主动认同既有的社会角色和规则。这意味着,意识形态最强大的效果恰恰体现在人们对其“自然性”的不自觉接受之中。

马克思恩格斯与阿尔都塞的理论贡献相互补充,前者揭示了意识形态的阶级本质与颠倒结构,后者揭示了意识形态的物质载体与主体生产机制。二者共同表明,意识形态既是观念的上层建筑,也是嵌入制度、技术和日常实践中的意义再生产装置。生成式人工智能作为当代最具渗透性的信息基础设施,正日益成为一种新型的意识形态机器,它以数据为记忆、以算法为逻辑、以生成内容询唤用户主体,从而在技术的客观外观下完成意识形态的自动化再生产。

(二)生成式人工智能意识形态属性的发生逻辑

生成式人工智能的意识形态属性,并非使用者主观赋予的外在标签,而是贯穿数据训练、模型开发和内容输出全链条的内在建构结果。从技术哲学的视角来看,生成式人工智能构成了一种物质化的意识形态,即它把特定历史阶段的社会权力关系、价值规范和符号秩序,凝结为可计算、可调用、可规模化扩散的技术装置。

在数据层面,训练语料是人类社会历史实践的数字化沉淀,天然携带特定时代的权力结构和价值印记。当生成式人工智能对这些语料进行统计拟合时,它并非在学习知识,而是在继承一种经过数字化的社会无意识。这种无意识中沉积的阶级、种族、性别和文明秩序,会转化为模型输出过程中的概率偏好,成为意识形态运作的底层逻辑。

在开发层面,价值对齐和安全过滤机制是开发者有意识地将特定共同体的规范嵌入技术架构的过程。这一过程与阿尔都塞所说的意识形态国家机器高度吻合,它通过区分合规与违规、正常与异常、安全与风险,把抽象的主导价值转译为可执行的算法规则,从而对用户实施温和而持续的主体询唤。用户在与模型的交互中,不断接受某种话语边界和价值框架的规训,逐渐将其内化为自身的认知前提。

在输出层面,生成式人工智能以低成本、高效率的方式生产海量符号内容,再生产符合主导权力结构的符号秩序。这种符号生产以温和、隐蔽、合法化的方式,使被支配者自觉接受支配者的意义框架,并把不平等结构视为理所当然,带有符号暴力特征。与传统符号暴力不同的是,生成式人工智能使符号暴力的生产从精英垄断转向大众化和自动化,极大拓展了意识形态再生产的时空、规模和速度。

综上,从马克思、恩格斯揭示的意识形态颠倒结构,到阿尔都塞阐明的意识形态物质存在和询唤机制,再到生成式人工智能对数据、算法和内容的系统整合,我们可以清晰地看到:生成式人工智能的意识形态属性不是外在于技术的附加结果,而是深度嵌入技术架构与运行逻辑的内在固有属性。这一判断是进一步分析其意识形态风险的认识论前提。

(三)偏见无意识内化于数据训练全过程

生成式人工智能对全网海量公开语料的预训练依赖,使得人类社会既有的结构性偏见会被算法无意识内化,成为生成式人工智能底层的隐性意识形态逻辑。众所周知,生成式人工智能的训练,以大规模数据投喂为基础。“海量的数据是生成式人工智能发展的必要条件,使用高质量和高关联度的数据训练人工智能可以快速提高人工智能算法的准确性。”[5]从技术本质来看,生成式人工智能数据处理的核心,是对全球互联网多模态海量语料进行统计拟合与概率建模,通过学习不同符号、概念之间的共现频率,归纳出符合语料特征的生成规律。这一过程,本身就是对既有数字公共文化的结构性继承,决定了生成式人工智能必然无意识内化人类社会既有的结构性偏见,典型案例就包括西方中心主义、种族歧视、性别刻板印象等。

究其根源,所有训练用的语料、数据等都不是自然生成的中性素材,而是人类社会历史实践的产物。这些内容本身就沉淀了不同历史阶段形成的结构性偏见,也内嵌着社会的权力不平等关系。而生成式人工智能不具备人类的意识形态主动辨识能力与批判能力,无法对这些潜藏的意识形态因素做主动筛选与清理。经其归纳拟合后的数据,必然保留原语料自带的社会属性与价值印记。

这一逻辑,直接挑战生成式人工智能领域秉持的数据中立论。该理论的核心主张可归纳为两点:一是将训练数据视为无偏向的经验原材料;二是将模型的归纳拟合过程等同于纯客观的概率计算,认为训练完成的生成式模型只是吸收人类文明既有知识成果的中性工具。但实际上,当前全球主流生成式大模型的训练语料超过70%来自英语互联网①,而英语互联网的内容生产本身就被西方资本、西方主流媒体所主导,天然带有西方中心主义的价值烙印,不可能存在完全中性的训练数据。因此,训练完成的生成式模型,会吸收人类文明的既有知识成果,也必然无意识继承内嵌于既有文化结构的偏见逻辑。

此判断已得到大量经验研究与事实证据的验证。职业性别刻板印象偏差就是一个典型例证。工业革命以来,逐步固化的职业性别分工偏见,会以职业标签对应性别、身份的高频共现形式留存于训练语料,被模型自动习得。当模型生成相关内容时,会惯性输出符合传统刻板印象的结果。如我们要求模型生成顶尖科学家与幼儿园教师的配图时,前者会被高概率配置男性图片,而后者则多被匹配为女性,充分体现了传统性别偏见的算法传承。另一类普遍存在的隐性偏差,出现在种族与文明层面。当前主流生成式模型常将专业、理性、领导力等正向特质更多关联给西方社会,而对非西方族群的形象塑造往往自带负面预设。这些都说明,当前生成式人工智能的数据训练过程,不可避免地复制既有社会的意识形态结构。

(四)价值观编码内嵌于安全对齐机制

如果说训练数据层面的偏见内化是权力结构的无意识沉淀,那么开发阶段的价值对齐过程,则是开发者有意识地将特定意识形态嵌入技术架构的编码过程。这一逻辑,在当前主流大模型的安全过滤体系中体现得最为淋漓尽致。所谓安全对齐机制,是约束人工智能模型生成内容、使其符合特定社会价值规范的运作流程,其核心任务是将抽象价值规范,转译为可执行的算法规则。它以开发者所处社

① 参见 arXiv. A Survey on Multilingual Large Language Models: Corpora, Alignment, and Bias, https://arxiv. org/html/2404.00929v3.

会的主导性政治、社会规范为标准,划定内容的安全边界,区分合规内容与风险内容,再依据预设规则触发过滤、拦截、标记等操作,最终让模型输出符合开发者预期的内容。

当前,人工智能领域对价值对齐普遍持去政治化解读。仅将其界定为消除模型幻觉、防范有害内容的纯技术过程。这种解读遮蔽了价值对齐的意识形态属性。事实上,价值对齐从模型建构之初,就是将特定共同体的价值规范嵌入模型的过程。其本质是让模型输出符合开发者所处社会的规则预期与价值偏好。这一过程就是典型的意识形态编码,是特定政治社会规范的技术化实现。开发者群体背后的国家利益、资本立场、价值观念,都会通过对齐过程完整嵌入算法逻辑之中。

进一步看,相较于显性的过滤规则,生成式人工智能对道德立场、政治立场的隐性预设隐蔽性更强,更难被公众察觉。开发者所处社会的主流道德共识与政治共识,会潜移默化塑造模型的编码逻辑,最终使得模型对不同议题的回应,呈现出符合既有秩序的系统性差异。例如在对成瘾性物质的议题讨论中,模型会对被社会共识明确禁止的物质强化风险警示,而对已经合法化的成瘾性物质则相对弱化其社会危害性表述。这种回应差异本身就是既有社会道德秩序的算法投射,是价值规范嵌入代码设计的直接体现。这足以说明,价值对齐过程绝非简单的中性技术调试。它是意识形态通过算法设计实现自动化编码的过程,算法由此成为意识形态传播的新型载体。

(五)符号暴力效应潜藏于生成内容

经过数据层面的偏见内化与开发阶段的价值观编码,生成式人工智能最终会在输出内容中持续再生产符合主导权力结构的符号暴力,这是其意识形态属性最直接的现实体现。法国社会学家皮埃尔·布迪厄在其符号暴力理论中解释了权力在文化、教育等领域的隐形运作方式。他指出,符号暴力是一种通过合法化的社会结构、习惯性实践以及象征体系施加的隐性压迫,施暴者和受害者往往都不自觉地接受并再生产这种压迫机制[6]。符号暴力通过主观规范和价值体系传达给处于从属地位的个体时发生作用,具有隐蔽性,被支配者不自觉地接受支配者的统治,并将这种不平等的结构视为“理所应当”。因此,符号暴力也被布迪厄称为“温和的暴力”。生成式人工智能输出的所有多模态内容,普遍携带这种由既有权力结构塑造的符号暴力,生成过程的每一步符号选择,都内嵌既有权力结构的印记。

传统符号暴力生产,高度依赖精英主导的场域。无论是教育、出版,还是传统大众传媒,符号生产都有着极高的准入门槛,资本、权力、专业身份都构成了天然壁垒,同时扩散范围也受到媒介容量、传播渠道的限制,符号暴力的生产与扩散效率有限。生成式人工智能的生成逻辑,彻底改变了这一生产格局。它以语料统计概率为基础生成内容,自然而然地放大了既有主导符号的影响力,因为主导符号本身在语料中的共现频率更高,算法会更倾向于选择符合主导逻辑的符号组合。同时,生成式人工智能大幅降低了内容生产的门槛,普通人只需要输入简单的提示词,就能快速批量生成多模态内容,符号暴力由此从精英垄断生产转向日常化、大众化生产,生成式人工智能为符号暴力的自动化、大范围扩散提供了核心技术可能。

无论是视觉生成,还是文本生成,生成式人工智能的输出结果都内嵌主导性意识形态的深层逻辑,其中更具危害性的是生成式人工智能对批判历史叙事的消解和对霸权历史叙事的自动化重构。当前全球主流生成模型处理殖民时代等敏感历史场景时,往往倾向输出平和日常的生活化画面,刻意淡化殖民体系下的暴力历史,其实质是以算法化的美学表征软化殖民历史的暴力性,遮蔽西方霸权的历史罪责,最终推动主导性霸权叙事在数字空间完成自动化再生产,潜移默化塑造全球用户对殖民历史的认知,从而不断巩固西方中心主义的话语霸权。正如技术哲学家兰登·温纳所言:“技术本身就是一种政治现象。”[7]277综上可见,从数据训练阶段对既有社会偏见的无意识内化,到模型开发环节对特定价值观的有意识编码,再到内容输出层面符号暴力的持续再生产,意识形态建构贯穿着生成式人工智能从开发到落地的完整生命周期。这表明生成式人工智能的意识形态属性绝非外在于技术系统的额外附加,而是深度嵌入技术架构与运行逻辑的内在固有属性。这是科学廓清生成式人工智能意识形态影响、防范化解相关安全风险的认识论前提。若要进一步拆解生成式人工智能意识形态风险的发生机理,仍需从根源层面展开更深层次的剖析。

二、生成式人工智能意识形态风险的成因分析

生成式人工智能作为人类劳动工具的革命性突破,其与生俱来的意识形态属性决定了它已然成为当前意识形态领域的新型载体,给国家意识形态安全带来全新挑战。互联网是意识形态工作的主阵地、主战场、最前沿,习近平总书记指出:“过不了互联网这一关,就过不了长期执政这一关。”[8]147生成式人工智能作为新一代信息技术的重要成果,正以前所未有的方式重塑社会生产、知识传播与观念建构的各个领域,成为意识形态风险的重要驱动因素。这要求我们清醒地认识到生成式人工智能意识形态风险并非单一技术因素导致的偶然结果,而是技术属性、权力结构与制度环境多重因素交织作用的必然产物,其风险根植于技术与社会结构的深刻互构。

(一)技术对社会存在的系统性重构引发意识结构异化

历史唯物主义认为,社会存在决定社会意识,生产工具的变革必然引发意识结构的深层调整。这种辩证运动在人工智能时代呈现出前所未有的复杂性。生成式人工智能对物质基础的重构效应,已远超蒸汽机革命、电力革命等传统技术革命的影响,它不再仅仅延伸人类的体力或简化重复性劳动,而是直接介入教育、文化生产、知识传播等关涉意识形态的关键领域,实现了劳动工具本身的意识形态化转型。马克思在《德意志意识形态》中指出:“意识在任何时候都只能是被意识到了的存在,而人们的存在就是他们的现实生活过程。”[9]525生成式人工智能对物质生产与知识生产的深度重构,从根本上改变了意识形态的存在基础,引发了意识结构的系统性异化,这是意识形态风险产生的内在根源。

这种异化最显著的特征,是工具理性对价值理性的殖民。具体而言,就是在生成式人工智能时代,技术理性成为统治的合法性来源,几乎所有的社会议题都被转化为技术问题,相关的结构性矛盾都被转化为个体选择问题,价值层面的批判性思考被彻底消解。哈贝马斯早在《作为“意识形态”的技术与科学》中就批判了这类现象,他指出,科技进步同旧的意识形态一样,也发挥着使人们安于眼下的生活状况,阻止他们思考和议论社会的基本问题的作用[10]5。但让人担忧的是,生成式人工智能让这一过程完全自动化。不需要刻意的意识形态引导,算法会在每一次内容生成中自动完成对议题的框架设置,把公众的注意力引向个体层面,遮蔽结构性的深层矛盾。对此,埃吕尔早就预言:“这些中介是如此扩展、延伸、增加,以至它们已构成了一个新的世界,我们已目睹了‘技术环境’的产生。”[11]如此,当成长于数字时代的原住民已经沉溺于算法、人工智能构筑的认知舒适区时,代际之间对历史、价值、社会的认知差异就会不断扩大,进而使得思想的统一性难以实现,意识形态的鸿沟会不断拉大,风险也随之增长。

(二)全球科技权力结构性失衡催生新型意识形态霸权博弈

当前,世界百年未有之大变局加速演进,新一轮科技革命和产业变革深入发展,使得意识形态领域的博弈全面渗入人工智能领域,并呈现新形态。生成式人工智能的发展高度依赖海量数据、巨额算力与顶尖研发团队,截至2025年第四季度,五大美国云巨头(微软、谷歌、亚马逊、Meta、甲骨文)合计持有全球AI算力的71%①。生成式人工智能领域的权力结构性失衡,使得生成式人工智能成为新型意识形态博弈的隐形战场,技术成为西方发达国家推行意识形态霸权的新载体,数字时代的数据殖民主义成为意识形态风险的重要外部来源。

语料库的地缘政治属性是数据霸权最直接的体现。作为大型语言模型(large language models,LLM)的GPT-3,是拥有1750亿参数的模型,它的训练语料构成如下:60%来自2016—2019年的Common Crawl语料库;22%来自Web Text语料库②。这种语料结构的失衡直接导致价值观的偏向,具体表现在以下两个方面:一方面,代表我国价值立场的内容,由于在语料库中占比极低且大量被西方叙事歪曲,最

① 参见Epoch AI. Five hyperscalers now own over two-thirds of global AI compute, https://epoch. ai/data-insights/hyperscalers-control-most-compute.

② 参见J. Sitkevich. GPT-3 A Powerful New Beginning, https://levelup. gitconnected. com/gpt-3-a-powerful-new-beginning-d809d21586.

终在模型的向量空间中被边缘化,甚至被错误归类,难以进入算法的核心语义空间;另一方面,我国公民尤其是青年在使用大模型时,必然身处西方意识形态的包围,“人类将数据转化为信息,然后将这些信息与之前的思想和经验结合之后,就产生了知识”[12]422,“所有的知识都来源于信息,并以人类之前相互交流的思想为基础”[12]425。这种数据霸权直接催生了知识生产的依附体系,广大发展中国家由于缺乏足够的算力和语料资源开发本土大模型,而被迫采用西方国家开发的模型处理本地公共事务。由此,极易出现西方国家通过垄断技术,实现对发展中国家知识生产的控制与意识形态的渗透。

更为被动的是,在对大模型语料进行训练的过程中,英语所占比重较高,算法标准的制定也成为西方社会的囊中之物,这些更成为西方价值观输出的精妙隐蔽通道。当前全球主流大模型的内容审核标准,实质是美国意识形态标准的算法封装,其标榜的“无害化训练”“价值中立”本质上就是美式自由主义的数字传教,因为算法标准直接决定了所输出数据的合法性、正义性以及可传播性。至此,资本与技术合谋的意识形态机器已经悄然完成了对全球公众意识的格式化工程。

(三)创新迭代与治理演进的断层开辟了风险滋生空间

生成式人工智能技术迭代的速度远超制度与治理演进的速度,创新与治理之间形成了明显的断层,监管滞后与全球治理碎片化为意识形态风险的滋生扩散提供了制度缺口。习近平总书记明确指出:“人工智能带来前所未有发展机遇,也带来前所未遇风险挑战。”[13]我国2023年出台的《生成式人工智能服务管理暂行办法》开篇就将促进生成式人工智能健康发展和规范应用,维护国家安全和社会公共利益,保护公民、法人和其他组织的合法权益作为立法的核心目标①,恰恰反映了治理滞后带来的风险已经成为亟待解决的重大问题。当前,新一代大模型的研发周期不断压缩,而无论是各国国内的立法还是跨国监管框架的构建,都需要启动繁杂的立法程序,历时一年或数年甚至十余年,这种技术创新与社会治理的剪刀差被资本和霸权力量利用,不断放大意识形态风险。

监管空窗期成为资本开展意识形态实验的合法空间。当前将未完成全部内容安全审核的人工智能模型投放至监管体系不完善的弱势地区,已经成为全球科技行业心照不宣的隐性实践。这一实践的本质是跨国资本利用不同国家的制度位差,将监管不足的弱势地区转化为自身的意识形态试验场。这种试验既可以通过用户交互采集本土化原生数据完成模型优化,又可以测试不同内容规则应用于不同社会语境的反馈,若风险发生,则依托开源模式的责任界定模糊性,以开发者自行负责为由转移风险责任,使自身免于追责。

生成式人工智能的算法黑箱特性会推动责任主体发生技术性隐匿,最终导致意识形态输出的责任链条发生系统性断裂。由于生成式内容的生成逻辑具有内生不可解释性,且内容生产入口对所有用户开放,当异质性意识形态渗透内容借助技术载体扩散后,平台往往将责任归因于算法本身的复杂性或用户的自发生产行为,使得绝大多数意识形态渗透行为无法完成责任追溯与追责。

全球人工智能治理的碎片化特征进一步放大了意识形态风险。不同国家人工智能治理的理念分歧为跨国平台实施意识形态双轨制提供了制度空间。当前全球人工智能治理领域已经形成清晰的理念分野,一方是以美国为首的欧美国家,秉持资本优先的逻辑,片面强调技术自由流动的绝对价值,本质上是为本国科技巨头的全球扩张与意识形态输出开辟道路;另一方是以中国为代表的发展中国家,坚持以人民为中心的发展思想,坚持发展与安全的辩证统一,主张人工智能发展应当服务于全人类共同利益。这种核心理念层面的分歧导致全球层面难以形成统一的人工智能意识形态治理规则,跨国科技平台借此对不同国家实施差异化的内容审核标准。在符合自身意识形态利益的场域放松内容约束,在意识形态对立国家收紧内容供给与传播权限,进一步加剧了全球意识形态领域秩序的混乱。

更值得警醒的是,前文论及的技术异化、霸权博弈、治理断层三重因素并非孤立存在,而是相互嵌入、相互强化的,最终形成了自循环、自增强的风险螺旋,构成了对当代意识形态安全的根本性挑战。

①参见中央网络安全和信息化委员会办公室、中华人民共和国国家互联网信息办公室:《生成式人工智能服务管理暂行办法》(2023年07月13日),https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm。

毛泽东同志曾说过:“掌握思想领导是掌握一切领导的第一位。”[14]435必须将意识形态工作作为一项长期的工作来抓,守好自己的阵地,无论任何时候、任何情况下都不能放松、不能落下,要时刻提高思想警惕、防微杜渐,否则就会犯下不可挽回的错误。这种隐蔽而深刻的意识形态风险,正是生成式人工智能作为人类劳动工具革命性突破带给当代文明的悖论性馈赠,也对我们防范化解意识形态安全风险提出了全新的时代命题。

三、生成式人工智能意识形态风险的防控路径

生成式人工智能引发的意识形态安全挑战,表象是技术迭代带来的治理难题,实质是智能时代意识形态领导权、管理权、话语权的现实较量。习近平总书记强调,要“建设具有强大凝聚力和引领力的社会主义意识形态”[1],并指出要“以新安全格局保障新发展格局,主动塑造于我有利的外部安全环境”[15]。这深刻启示我们,风险防控不能止步于技术层面的查漏补缺,而必须回到意识形态工作的根本定位上来,以巩固马克思主义在意识形态领域的指导地位、巩固全党全国人民团结奋斗的共同思想基础为根本目标,以牢牢掌握意识形态工作领导权、管理权、话语权为实践牵引,推动技术自主与价值引领同频共振、制度规范与思想建设同向发力,实现从守住阵地向赢得人心的跃升。

(一)营造韧性包容的环境生态

意识形态阵地,如果真理不去占领,就会被谬误盘踞。应对生成式人工智能的意识形态风险,首先要解决阵地问题,要超越传统物理空间的防御思维,把技术平台、算法模型、语料数据都视为意识形态的新阵地来经营,在文明对话中筑牢意识形态安全防火墙,构建数字文明的精神免疫系统。从马克思主义意识形态理论来看,意识形态的再生产从来不是自发完成的,而是在特定的制度环境、教育体系与社会心理中进行的;因而营造环境,本质上就是营造马克思主义能够广泛传播、社会主义主流价值能够牢固生根的社会条件。这既是落实意识形态工作责任制中阵地管理要求的应有之义,又契合了总体国家安全观坚持系统观念、筑牢安全防线的根本要求。

首先,从国家法治层面,需加快完善专项立法体系,以刚性制度明确生成式人工智能意识形态安全底线。法从来不是超阶级的技术规范,而是国家意志的规范化表达,是意识形态领导权的制度化形态。我国已出台行业基础性规则,下一步应推进专项立法,把社会主义核心价值观融入人工智能法治建设全过程,落实《中华人民共和国国家安全法》对网络安全、文化安全的法定要求,将价值观嵌入要求正式纳入国家技术标准体系。该标准体系需包含三大核心机制:一是预训练审查机制,要求基础模型开发者备案时提交正式的价值观对齐方案,参照国际监管经验,使用对抗样本测试模型的历史观、价值观偏差;二是动态熔断机制,明确意识形态偏差阈值,算法输出偏差超过安全标准时,自动触发模型修正流程;三是文化安全准入条款,教育、新闻出版、传媒等意识形态敏感领域,仅允许通过安全认证的国产合规模型接入,落实意识形态工作责任制的阵地管理要求。这些设计既是葛兰西“文化领导权”理论的数字实践,更是通过法治框架把“党管宣传、党管意识形态”的根本原则转化为可落地、可量化的技术参数,使刚性制度真正成为价值底线的守护者。

其次,从社会培育维度,需启动全民“认知免疫工程”,通过教育升级筑牢全民思想防线。意识形态工作本质上是争取人心的工作,其成效最终取决于社会成员的价值判断力与政治鉴别力。过度依赖人工智能生成内容,不仅会弱化公众的批判性思维能力,而且会在潜移默化中催生智能时代的数字拜物教,把算法输出的内容当作客观知识,这正是马克思所批判的拜物教意识在数字条件下的表现。落实中央关于提升全民数字素养与技能的要求,需要通过教育变革重构公众思维韧性,把立德树人根本任务延伸到人机关系领域。基础教育阶段需引入人机辩证训练,培养价值判断与批判性思维能力。这种教育不是反技术的怀旧,而是杜威“做中学”理念的当代诠释,核心是在技术应用中培育公众驾驭技术的主体意识,使社会主义核心价值观真正内化为人们的精神追求、外化为人们的自觉行动。社会层面需同步构建人工智能伦理素养认证体系,将人工智能意识形态鉴别能力纳入公务员考核、教师资格认

定、媒体从业准入标准,把政治判断力、政治领悟力、政治执行力的要求具化到关键岗位的准入条件与评价体系之中,推动关键岗位落实意识形态安全责任。

最后,从全球治理场域,需推动构建数字文明新秩序,践行全球文明倡议,守护文明多样性。意识形态领域的较量从来不止于一国之内:个别西方大国长期凭借技术与平台优势,把特定的价值观念包装为“普世价值”向外输出,以数字殖民的方式推行文化霸权,其实质是以技术优势巩固其意识形态霸权。针对跨国科技企业的数字文化殖民行为,我国应联合“全球南方”国家,在多边框架下推动达成数字文明多样性共识,打破西方对国际话语规则的垄断,确立人工智能文化主权原则:一是数据反哺条款,要求跨国企业将当地语料开发收益按合理比例投入本土文化数字化保护;二是算法多元性披露要求,强制企业公开模型在非西方价值观测试中的表现,接受全球监督;三是紧急文化干预权,检测到系统性抹黑民族文化的生成内容时,主权国家有权对相关服务采取管控措施。同时,要加快构建中国话语和中国叙事体系,用中国理论阐释中国实践、用中国实践升华中国理论,把全球文明倡议从理念主张转化为可操作的国际规则。这种框架既非封闭排外,又不对霸权妥协,是在坚持马克思主义意识形态阶级分析方法的基础上,守护技术时代世界文明多样性的根基。

(二)锻造自主可控的技术基座

技术基座自主可控,是保障生成式人工智能意识形态安全的核心前提。在智能时代,谁掌握了基础模型、语料资源与算力平台,谁就掌握了意识形态生产的技术制高点。核心技术一旦受制于人,意识形态的防线再严密,也难免建在别人的地基上。只有在算法革命中注入中华文明核心基因,实现从追赶式创新到范式引领的跃迁,才能从根本上摆脱西方技术与意识形态的双重牵制。这是落实“加强研判,统筹谋划,协同创新,稳步推进,把增强原创能力作为重点,以关键核心技术为主攻方向,夯实新一代人工智能发展的基础”[16]部署的必然要求,也是把意识形态工作领导权、管理权、话语权落到技术层面的必由之路。

首先,从基础模型层面,需实施“中华文明编码计划”,将中华优秀传统文化与社会主义核心价值观深度融入算法架构。马克思恩格斯指出,意识形态“没有历史,没有发展”[9]525,其独立性不是凭空生成的,而是训练语料中价值分布的技术投射。自主训练基础模型因此具有突出的战略紧迫性。落实构建自主可控人工智能技术体系的要求,我们要整合各类中华文化资源,构建规模宏大的中华文明语料库。该工程需融合传统训诂学与现代人工智能技术,训练模型要正确把握中国话语的内在逻辑,避免片面绑定西方民主叙事,使中华文明的精神标识和文化精髓成为模型的底层知识。在此基础上推进神经网络架构创新,研发带价值感知功能的模型架构,在注意力机制层添加价值观权重矩阵,当生成涉及集体利益的内容时,自动强化“天下为公”“大同”等思想对极端个人主义的制衡。这种设计不是简单的政治标注,而是将中华优秀传统文化的精神基因转化为算法的内在逻辑,使之升华为模型生成内容的价值指引。

其次,从数据治理领域,需构建“双循环流通体系”,以数据正义保障文化本真性。数据并非天然中立的原材料,每一次采集与标注都是一次价值选择;数据的流向与标注规则,直接决定模型意识形态的倾向。对内落实铸牢中华民族共同体意识要求,建立覆盖各民族的文化数据图谱,运用联邦学习技术实现“数据可用不可见”,在增进共同性的同时尊重和包容差异性,防止算法以尊重差异为名放大族群隔阂。各民族文化资源在本地完成价值观预处理后,生成的文化向量可安全汇入国家模型训练池,既保障数据安全,又实现文化资源整合利用。对外落实全球发展倡议,创建跨区域文化数据合作网络,在枢纽节点部署分布式数据清洗站点,通过区块链存证技术保障沿线国家文化资源数字化过程中的本源性,避免被西方算法歪曲。这套体系的核心是建立数据正义协议:所有训练数据标注员必须通过马克思主义文化理论考核,标注过程采用“双盲三审”制,由多学科学者独立审核,从源头杜绝西方意识形态通过数据标注渗透引发的伦理危机。

最后,从算法监管维度,需研发意识形态风险智能监测工具,把党管意识形态要求落实到算法监管全过程。算法从来不是纯粹的技术中立物,其目标函数、排序规则、推荐逻辑无不内嵌着设计者的价值

判断。落实习近平总书记“提高我国数字经济治理体系和治理能力现代化水平”[17]208的要求,应坚持党管互联网、党管意识形态原则,基于可解释人工智能技术开发意识形态风险评估平台,把马克思主义立场观点方法转化为可计算、可验证的评估指标,对模型生成路径进行全链条拆解,定位受外来意识形态渗透影响的算法环节。配套监管工具包含三大核心功能:一是偏差矫正功能,实时监测生成内容的价值偏向,在出现价值偏差时自动注入符合我国主流价值观的内容以矫正偏差;二是认知平衡功能,在用户持续接收单一视角信息时,强制插入辩证视角内容,保证信息供给的全面性;三是源头追溯功能,通过模型水印技术追溯深度伪造的政治虚假信息,实现快速溯源。这些技术共同构成数字时代的意识形态免疫监视系统,实现由抽象国家意志向可编程算法规则的转化。

(三)构建智慧响应的能力中枢

防范化解生成式人工智能领域的意识形态风险,必须清醒认识到:意识形态风险不同于一般的技术性、操作性风险,其本质是政治风险,是关系政权安全、制度安全的根本性问题。因此,其风险应对不能停留于发现、处置的被动防御,而必须转向主动塑造,在认知战场掌握意识形态斗争的战略主动权。要建立政治引领与技术赋能相统一的智能治理体系,把时度效原则贯穿风险识别、预警响应、处置修复全过程,这是推进国家安全体系和能力现代化的必然要求。

首先,在风险识别环节,需构建多模态精准识别体系,实现意识形态风险的精准定位。意识形态风险的隐蔽性在于其话语包装,历史虚无主义往往以“还原真相”的面目出现,西方错误思潮常常借“学术讨论”“价值中立”之名传播,单纯的关键词过滤既容易误伤,更难以触及话语背后的价值逻辑。因此,识别体系建设必须由字面识别走向逻辑识别,把政治敏锐性和政治鉴别力的标准嵌入算法。结合神经科学相关研究成果,开发生理-语义多模态风险识别系统,捕捉用户接触风险内容后的异常反应,平台即时推送权威内容开展认知干预。国家级监测中心运用先进计算技术优化语义分析,构建权威意识形态知识图谱,所有内容标准以中央审定口径为依据,清晰地呈现西方意识形态的本质与发展谱系,揭示其在智能时代的变异形态与传播策略,打破西方话语包装。这种识别模式超越了传统的关键词过滤,能够深度识别隐含的意识形态风险,大幅提升识别精准度。

其次,在预警响应环节,需建立一体化风险预警响应机制,把风险化解在萌芽状态。时机与节奏是意识形态领域斗争的重要影响因素。基于意识形态风险的演化规律,开发多要素耦合预警平台,将舆情热度、传播路径、群体结构与价值偏向纳入统一模型,能够提前预判风险演化路径,当风险突破预设阈值时自动触发应急预案,为赢得先机、争取主动留出宝贵时间。响应机制遵循“神经可塑性修复”原理,针对不同群体开展精准干预,对易感人群优先推送权威信息,对已形成错误认知的群体开展系统性的思想引导,增强公众对错误思潮的批判能力。

最后,在处置修复环节,需形成全链条“认知生态治理”,实现风险处置与价值巩固的统一。意识形态工作的终极目标是赢得人心、凝聚共识。要坚持党对意识形态工作的全面领导,在党委统一领导下建立智能化风险处置指挥中心,严格落实意识形态工作责任制,将风险处置成效纳入领导班子和领导干部考核评价,落实风险处置“三同步”要求:舆情管控同步开展价值修复,删除虚假信息时同步推送权威内容以澄清误解,并以此为契机讲清道理、凝聚共识;技术处置同步启动责任追溯,违规模型的改造过程全程留痕存证,明确主体责任;短期应对同步推动制度革新,处置案例及时汇入规则完善的实践依据库。处置效能通过“意识形态健康指数”量化评估,在集体记忆完整度、价值观韧性、技术自主性三大核心维度的基础上,增加政治认同度、主流舆论引导力、错误思潮免疫力等政治性指标,使评估真正反映意识形态工作的本质要求。在此基础上搭建跨学科认知修复平台,由宣传思想工作者、马克思主义理论专家、心理学者与技术工程师共同组成专业团队,对算法造成的认知创伤开展系统性修复,引导公众重建正确的价值观念。

(四)铸牢凝心铸魂的价值根基

技术可以封堵风险,制度可以划定边界,但真正能够长久守护意识形态安全的,是思想上的坚定与价值上的认同。环境生态、技术基座与能力中枢,都是外部条件;若没有坚实的思想根基与过硬的主体

力量,再严密的防线也可能在价值虚无中松动。因此,必须把铸牢价值根基作为全部防控路径的灵魂工程。

首先,强化马克思主义在意识形态领域的指导地位,用党的创新理论引领智能时代的思想建设。要坚持以习近平新时代中国特色社会主义思想特别是习近平文化思想、习近平总书记关于网络强国的重要思想为指导,深刻把握智能时代意识形态工作的规律性认识。要加快构建以马克思主义为指导的智能时代话语体系,围绕人工智能的价值负载、算法正义、数字劳动、人机关系等重大议题推出一批标识性概念与原创性成果,用中国理论解释中国实践,用中国实践升华中国理论。

其次,以社会主义核心价值观引领网络意识形态阵地建设,壮大主流思想舆论。要把主流价值导向贯穿算法设计、内容分发与平台运营全过程,推动主流媒体加快全媒体传播体系建设,运用生成式人工智能提升主流舆论的感染力,实现主流价值与智能技术的双向赋能。要把网上舆论引导与网下思想教育贯通起来,在网络空间旗帜鲜明地反对历史虚无主义,同时又善于以理服人、以情动人,在辨析比较中增进公众对主流价值的认同,防止把政治原则问题简单化、口号化。要深入实施网络文明建设,使社会主义核心价值观成为智能空间最鲜明的精神底色。

最后,锻造政治过硬、本领高强的意识形态工作队伍,为智能时代的意识形态斗争提供主体支撑。意识形态领域的较量,归根到底是人的较量。要坚持党管宣传、党管意识形态、党管媒体原则不动摇,把政治能力作为第一能力,把讲政治的要求贯穿队伍建设全过程。要着力提高领导干部的政治判断力、政治领悟力、政治执行力,使其既懂技术逻辑,更懂政治逻辑,善于从政治上观察和处理技术问题。要培养造就一批既懂马克思主义理论又懂人工智能技术的复合型人才,使其成为连接理论话语、技术话语与大众话语的纽带。要严格落实意识形态工作责任制,做到守土有责、守土负责、守土尽责,确保党牢牢掌握对意识形态工作的领导权。

四、结语

生成式人工智能的普及重塑了意识形态生产、传播与博弈的底层逻辑,技术并非价值中立工具,而是内嵌价值偏见、承载意识形态博弈的新型数字载体。数据偏见内化、价值对齐编码、符号暴力输出共同构筑其内在意识形态属性,叠加技术异化、全球科技霸权失衡、治理滞后三重诱因,持续催生隐蔽复杂的意识形态安全风险,对我国意识形态领导权与总体国家安全构成长期挑战。化解此类风险不能单纯依靠技术封堵或事后管控,需构建生态、技术、治理三位一体的系统性防控体系。一方面,完善法律法规,构筑全民数字认知免疫系统,共建多元包容的全球数字文明秩序;另一方面,攻坚自主可控大模型基座技术,融入中华优秀文化与主流价值,配套智能监测预警机制,实现风险主动识别、精准干预与认知修复。面向未来,我们要坚持统筹发展和安全,以自主技术筑牢安全屏障,以综合治理塑造有利认知场域,牢牢掌握数字时代党对意识形态工作的领导权,推动人工智能健康有序发展,维护国家意识形态安全。

参考文献:

[1] 习近平著作选读:第 1 卷[M]. 北京:人民出版社,2023:36.

[2] 习近平.论党的宣传思想工作[M]. 北京:中央文献出版社,2020.

[3] 马克思恩格斯选集:第 1 卷[M]. 北京:人民出版社,2012:178.

[4] 阿尔都塞.哲学与政治:阿尔都塞读本[M]. 陈越,编译. 长春:吉林人民出版社,2003.

[5] 安俊秀,叶剑,陈宏松,等.人工智能原理、技术及应用[M]. 北京:机械工业出版社,2025:10.

[6] Bourdieu P. Symbolic power[J]. Critique of Anthropology,1979(04):77-85.

[7] 温纳.自主性技术:作为政治思想主题的失控技术[M]. 杨海燕,译. 北京:北京大学出版社,2014.

[8] 习近平著作选读:第 2 卷[M]. 北京:人民出版社,2023.

[9] 马克思恩格斯文集:第 1 卷[M]. 北京:人民出版社,2009.

[10]哈贝马斯.作为“意识形态”的技术与科学[M].李黎,郭官义,译.上海:学林出版社,1999.
[11] Jacques Ellul . The Technological System[M]. New York:Continuum,1980:38.
[12] Jorge Reina Schement ,eds.Encyclopedia of Communication and Information[M]. New York:Macmillan Reference,2002.
[13]习近平在中共中央政治局第二十次集体学习时强调 坚持自立自强 突出应用导向 推动人工智能健康有序发展[N].人民日报,2025-04-27(01).
[14]毛泽东文集:第2卷[M].北京:人民出版社,1993.
[15]习近平主持召开二十届中央国家安全委员会第一次会议强调 加快推进国家安全体系和能力现代化 以新安全格局保障新发展格局[N].人民日报,2023-05-31(01).
[16]习近平在中共中央政治局第九次集体学习时强调 加强领导做好规划明确任务夯实基础 推动我国新一代人工智能健康发展[N].人民日报,2018-11-01(01).
[17]习近平谈治国理政:第4卷[M].北京:外文出版社,2022.

(责任编辑:王 蕾)

Emergence and Control of Ideological Risks in Generative Artificial Intelligence

Li Jin[1], Xu Xiaofeng[2]

(1. *School of Marxism*, *Hainan Normal University*, *Haikou* 570100, *China*;
2. *School of Marxism*, *Harbin Normal University*, *Harbin* 150025, *China*)

Abstract: Generative artificial intelligence has achieved a paradigm shift from discriminative to generative technology. The power of information production is partially ceded from human subjects to intelligent algorithms, which drives major changes in the logic of ideological production, dissemination and contention. The ideological attributes of generative artificial intelligence run through its entire technological life cycle, manifested in three aspects: the unconscious internalization of existing social structural biases in data training, the conscious encoding of specific values via safety alignment mechanisms during model development, and the continuous reproduction of symbolic violence compatible with dominant power structures in content output. The systematic reconstruction of social existence by technology triggers the alienation of consciousness structure, the structural imbalance of global technological power spawns new contests of ideological hegemony, and the mismatch between innovation iteration and governance evolution opens up space for risk breeding. These three factors serve as important causes of ideological risks in generative artificial intelligence. In response, it is necessary to foster a resilient and inclusive ecosystem, forge an independent and controllable technological foundation, build a smart and responsive capability hub, and consolidate the value foundation for uniting the people and forging their spiritual identity. In this way, a systematic prevention and control system for ideological risks of generative artificial intelligence can be established, providing theoretical references and practical paths for the Party to firmly hold the leadership of ideological work in the digital era and safeguard holistic national security.

Key words: generative artificial intelligence; ideology; risk prevention and control