生成式人工智能背景下高校意识形态风险新态势及应对路径*

□陈慧敏 刘钊宁 庄 臣

【摘要】高校是我国意识形态工作的前沿阵地。近年来，生成式人工智能的发展与普及在为高校师生提供诸多便利的同时，其趋同性、自主性与涌现性等技术特性给当前我国高校意识形态工作带来了系统风险、价值失控与风险突现等新的风险类型与风险特征，对当前我国高校的意识形态工作提出了新的挑战。要有效应对这些风险，就需要从多方面着手，构建“技术—制度—教育”的综合治理体系，形成协同治理效能，为新时代高校意识形态安全建设提供有力支撑。

【关键词】生成式人工智能；意识形态；高等教育
DOI:10.19400/j.cnki.cn10-1407/g2.2026.04.010

New Trends and Countermeasures of Ideological Risks in Colleges and Universities Against the Background of Generative Artificial Intelligence

CHEN Hui-min, LIU Zhao-ning, ZHUANG Chen

Abstract: Colleges and universities serve as the frontline of ideological work in China. In recent years, the development and popularization of generative artificial intelligence have brought great convenience to teachers and students in higher education institutions. Meanwhile, its technical characteristics such as convergence, autonomy and emergence have given rise to new forms and characteristics of risks in the ideological work of Chinese colleges and universities, including systemic risks , value anomie and sudden risk outbreaks, posing new challenges to contemporary ideological work in higher education. To effectively address these risks, a comprehensive governance system of integrating technology, institutions and education should be constructed through multi-dimensional efforts to achieve collaborative governance effects, so as to provide strong support for the construction of ideological security in colleges and universities in the New Era.

Keywords: Generative Artificial Intelligence; ideology; higher education

习近平总书记曾在全国宣传思想工作会议上强调：“意识形态工作是党的一项极端重要的工作。”[①]党的二十届四中全会提出，要“加强舆论引导，有效防范化解意识形态风险”[②]等重要要求。高校是我国意识形态工作的前沿阵地和重点领域，[③]完善高校意识形态工作责任制、有效防范化解高校意识形态风险，既是坚守社会主义办学方向的政治保障，也是践行立德树人根本任务的迫切要求，[④]对于维护国家安全、社会稳定具有关键意义[⑤]。

当前，以人工智能为代表的技术创新发展深刻重构了传统的信息传播方式，对意识形态工作提出了新的挑战，[⑥]尤其是生成式人工智能（Generative Artificial Intelligence），正在以其深度语义理解、高质内容生成、良好交互体验等技术和功能特性重塑意识形态的生成和传播机制[⑦]。作为年轻一代的高校学生往往是新技术的最先使用者，[⑧]是技术与创新扩散的“意见领袖”和“代理人”，[⑨]也是生成式人工智能应用最早一批深度用户。相应地，他们也是当前生成式人工智能背景下意识形态新风险的首当其冲者。质言之，不论从高校作为意识形态工作前沿阵地的极端重要性的角度，还是从高校学生作为生成式人工智能技术意识形态风险重点人群的角度来看，对生成式人工智能背景下高校意识形态风险展开分析探讨，是当前意识形态研究与高等教育研究共同的题中之义。

近年来，国内学界敏锐地把握了这一研究动向，

* 本文系2024年度北京高校思想政治工作研究课题重点项目“高校涉意识形态网络舆情应对机制研究”（项目编号：BJSZ2024ZD02）、2024年清华大学学生工作研究项目重点项目“网络思政与新媒体矩阵建设与管理的经验与启示研究”（项目编号：THXSGZ2024-ZD-08）的阶段性成果。

在生成式人工智能背景下的意识形态风险问题上开展了较为丰富的研究工作。目前，学界对于生成式人工智能背景下意识形态风险的分析主要从风险形成和风险后果两个方面展开。

从风险形成的角度来看，学者李瑞奇、李高磊将生成式人工智能潜在的意识形态风险分为原生风险、共生风险和孳生风险三种类型，原生风险指生成式人工智能自身技术特性带来的风险，共生风险指生成式人工智能技术与资本等其他要素联结产生的风险，孳生风险指生成式人工智能除原生和共生风险外对社会产生的影响更加深远的风险类型。[10]祝黄河、凌学武采用了类似的分类标准，将生成式人工智能潜在的意识形态风险归为自生、派生和继生三类，分别对应侵蚀个体认知、冲击公共议题、消解社会信任等风险。[11]从风险后果的角度来看，有学者从个体影响层面着眼，如谢成宇、徐荧松将生成式人工智能潜在的意识形态归纳为内容失实、价值失落和认知失稳三个层层递进的方面；[12]刘成、莫生叶在内容和价值层面的基础上增加了“社会分化”和“生活异化”两个风险类型；[13]也有学者从更加宏观的社会影响层面着眼，如孔德臣、侯勇认为生成式人工智能具有意识形态渗透、主流思想弱化、网络舆论操纵等风险；[14]刘文郡认为生成式人工智能可能会放大个人主义、激发行业震动、消解主流价值；[15]魏屹东、李煜慧指出生成式人工智能存在冲击主流舆论、造就“技术利维坦”等风险；[16]帅建强、韩源则提出了场域失落、话语旁落、治理失效三个方面的意识形态风险类型。[17]同时，高校作为意识形态工作的前沿阵地，自然也是生成式人工智能背景下意识形态风险问题的重要研究对象。孙鹏、甘翔认为生成式人工智能在高校普及应用的过程中会存在操控学生认知、侵犯数据主权、解构事实真相等风险；[18]路坤皓、郝文斌认为生成式人工智能会造成人机异化，在高校学生群体中形成技术崇拜，进而导致主流话语权力的流散，带来严重的意识形态风险。[19]

上述研究对生成式人工智能背景下的意识形态风险问题进行了较为全面的研究，总体上集中围绕用户认知、价值、思想等个体层面以及社会舆论、社会价值、社会信任等社会层面展开探讨，为该议题的后续研究提供了良好的基础。但不得不指出的是，上述研究总体上仍存在一定的局限性：第一，既有研究大多仍在讨论数字媒介意识形态风险的普遍性问题，未能真正从生成式人工智能这一新技术自身的特性出发探究生成式人工智能背景下意识形态风险的特殊性，这种不加区分的技术担忧本质上是一种过度的技术保守主义，既不利于厘清生成式人工智能背景下意识形态风险问题的本质，更不利于理论发展和实践应用。第二，既有研究较少对意识形态概念进行辨析界定，有将概念泛化之嫌。第三，既有研究对生成式人工智能引发的高校学生群体意识形态风险关注较少，未能充分关注到高校学生群体在意识形态问题上的特殊性。

据此，本文拟从生成式人工智能自身的技术特殊性与高校学生的群体特殊性出发，在厘清意识形态概念内涵的基础上，对生成式人工智能背景下高校意识形态风险问题进行更加具体深入的分析，旨在得到更切合时代背景、更具解释力的风险研判，并提出更具针对性的治理建议。

一、高校意识形态工作的内涵与特征

意识形态（idéologie）一词最早由法国哲学家特拉西（Destutt de Tracy）提出，特拉西将两个希腊词语“ιδεα”（思想、观念）、“λογος”（逻辑、学说）组合创造了这个概念，用以指代观念科学，即有关观念的本体论、认识论和方法论。[20]马克思承继了前人对这一概念的探讨，并建立了“第一个关于意识形态的理论”，[21]深化了意识形态概念的内涵和外延，推动了意识形态概念的广泛传播。[22]马克思将意识形态界定为一个有关人的意识和思想观念的范畴，包括政治思想、法律思想、道德、哲学、艺术、宗教等意识形式。[23]党的十八大以来，以习近平同志为核心的党中央从坚持和发展中国特色社会主义的战略高度对党的意识形态工作理论进行了丰富和发展，给予了意识形态工作明确的“极端重要”的战略地位。[24]我国社会语境下的意识形态概念总体上是一个和现实高度关联的政治范畴，包括社会思潮、文化思想和国家权力等多重内涵。[25]相较于其他社会群体，高校师生在思想思潮方面更加活跃，因此，我国高校群体语境下的意识形态更多是侧重于社会思潮和文化思想层面，即高校师生的思想意识、价值观念等问题。相应地，我国高校意识形态工作的内涵，本质上就是使师生自觉并自愿按照社会主义核心价值观来指导自己思想和行动，[26]使马克思主义的思想理论与社会主义核心价值体系成为高校师生思想与思潮的主流。

对于高校学生群体思想思潮形成和传播所潜在的意识形态风险问题的探讨，理应将当前我国高校学生的群体特征作为起点。只有准确把握当前我国高校学生的群体特征，才能更好地认识和应对高校的意识形态风险问题。从思潮思想的形成与传播角度来看，当前我国高校学生具有以下认知和行为特征。

第一，价值易塑性，这是高校学生群体认知发

展阶段的特殊性。高校学生群体正处于皮亚杰（Jean Piaget）认知发展理论中的形式运算阶段向后形式思维过渡的关键期，[27]其认知结构呈现出双重特征：一方面，他们已具备抽象逻辑思维能力，能够进行复杂的概念推理与假设检验；另一方面，其辩证思维能力尚未完全成熟，对复杂社会现象的认知往往呈现出非黑即白的二元对立倾向。从意识形态建构的视角看，高校学生又正处于埃里克松（Erik H. Erikson）人格发展理论中的“自我同一性对角色混乱”阶段，[28]其世界观、人生观、价值观以及政治态度正处于关键塑型期。这种认知特征使他们在面对生成式人工智能生成的海量信息时，既表现出强烈的求知欲与探索欲，又缺乏足够的信息甄别能力与批判性思维素养。

第二，技术依赖性，这是高校学生群体信息行为模式的特殊性。当代高校学生作为典型的“数字原住民”群体，其信息获取、处理与传播行为呈现出鲜明的代际特征。他们生长于互联网已相对普及的环境中，对新兴技术具有天然的亲近感与较高的接受度，但同时也是较易滥用技术、形成技术依赖的群体。[29]当前，生成式人工智能正在成为高校学生群体学习和社交的重要工具，当高校学生群体对于生成式人工智能的使用惯性一经形成，就很可能演化为技术依赖，生成式人工智能也很可能会取代家长和教师成为其遇到问题寻求帮助的第一选择，这也可能会带来高校思政教育失能的潜在风险。

第三，情感驱动性，这是高校学生群体心理需求结构的特殊性。高校学生群体的心理需求结构呈现出复杂性与矛盾性：一方面，他们渴望独立自主，追求个性解放；另一方面，又面临学业压力、就业焦虑、人际关系等多重挑战，存在强烈的情感认同需求与身份焦虑。这种心理特征使其在面对智能生成内容，尤其是个性化、迎合性内容时，极易产生情感共鸣与价值认同。凭借其语义理解与情感计算能力，生成式人工智能能够精准捕捉用户心理需求，生成具有高度情感共鸣的内容。若被不当利用，例如，针对学生的就业焦虑生成宣扬“读书无用论”“躺平主义”的“心灵鸡汤”，针对其身份认同困惑推送极端个人主义、虚无主义的内容，可能引发通过情感共鸣绕过理性防御，实现错误意识形态的软植入。

综上所述，我国高校学生群体当前正处于认知、行为和思维模式形成的快速发展期，其在认知层面的价值易塑性、在行为层面的技术依赖性与心理层面的情感驱动性等群体特征，都在客观上为高校意识形态风险的形成提供了一定条件。认识和把握高校学生的上述群体特征，对于研判和应对生成式人工智能背景下高校意识形态的新态势具有重要意义。

二、生成式人工智能背景下高校意识形态风险的新态势

学界部分研究针对生成式人工智能背景下的意识形态风险问题已开展了一些探讨，但大多将生成式人工智能与更广泛意义的人工智能等同，未能认识到生成式人工智能背景下高校意识形态风险的特殊性。要深刻理解生成式人工智能背景下高校意识形态风险的新态势，理应要从生成式人工智能自身的技术特性出发。

（一）趋同性与系统风险

趋同性是生成式人工智能相较于前序人工智能技术的一项显著特征。生成式人工智能的趋同性包括三方面内涵：第一，数据趋同，指用于训练大语言模型及其他生成式模型的数据集在来源、构成与价值取向上呈现出高度的同质化特征。当前主流生成式人工智能模型的训练数据高度依赖于公共互联网，尤其是维基百科、Common Crawl、Reddit、GitHub 等大型公开数据集。第二，模型趋同，生成式人工智能在基础模型、核心算法与系统架构上呈现出高度的一致性与路径依赖，一方面，基础模型的“赢者通吃”格局日益凸显，以 OpenAI 的 GPT 系列、Google 的 Gemini 系列、阿里的 Qwen 系列等为代表，少数几个科技巨头凭借其雄厚的资本与算力资源，成功训练出性能卓越的基础模型，并通过 API 接口或开源许可的方式，成为整个生成式人工智能生态的底层基础设施；另一方面，模型架构的路径依赖日益严重，自 Transformer 架构被证明在序列建模上的卓越能力以来，它已成为生成式人工智能领域近乎标准化的技术范式。数据和模型的趋同很可能会带来内容生成的趋同，2025 年国际著名神经信息处理系统会议（NeurIPS 2025）的最佳论文证实了这一现象：该研究通过实证发现了当前生成式人工智能存在的“人工蜂群效应”，即同一个生成式人工智能模型对同一个问题的回答存在趋同性，不同模型对同一个问题的回答也往往非常相似，即使模型之间没有共享训练数据，而这很可能会造成人类思维的长期同质化与价值观的单一化。[30]第三，应用趋同，指用户在生成式人工智能产品选用上形成了高度趋同性。以 2025 年 6 月数据为例，据网站通讯流量监测机构 StatCounter 统计，2025 年 6 月全球生成式人工智能产品中 OpenAI 的 GPT 系列市场占比接近 80%，除 GPT 系列、Google Gemini、Deepseek 等 6 款较知名的产品外，其余生成式人工智能产品的市

场占有率不到1%，[31]可见，当前全球范围内用户对于生成式人工智能产品的选用偏好高度一致。

生成式人工智能在数据、模型和应用三方面的趋同性很容易造成用户在使用、认知乃至思维模式上的趋同。这种底层技术逻辑的一致性，极易超越工具层面，诱发用户在使用习惯、认知框架乃至思维模式上的同质化风险。这一现象在创意写作领域已得到实证：有研究表明，尽管生成式人工智能能够作为有效的辅助工具增强作家的个人创造能力，但这种个体层面的增益却伴随着集体层面的损失——即创新内容多样性的显著降低。[32][33]类似的问题同样深刻影响着科学研究的生态：有研究发现，虽然利用生成式人工智能可以提升研究效率，但也会造成科学研究在整体层面的视野局限化，并会减少科研工作者之间的协作。[34]简言之，生成式人工智能基于算法逻辑的标准化介入，虽然能够提升个体在特定领域的产出效率与表现，但也导致了集体创新性的降低。这种现象本质上是因技术趋同而导致的思维路径依赖和趋同，其后果并非仅限于认知和思维均质化，更潜藏着一种更为严峻的非线性风险：生成式人工智能的趋同性往往如同一面透镜，将现有的优势与劣势同步放大，从而形成一种“使好的更好、坏的更坏”的放大效应。优质信息和良性互动会依托用户在应用上的趋同传递给每个人，但与之伴随的负面影响也可能会广泛地带给每位用户。

从意识形态风险的角度而言，这种放大效应可能会使用户在使用过程中潜在的某种个体风险普遍化：例如某种包含错误思潮的内容会被生成式人工智能反复生成，某种包含偏见的认识会被反复推送，以往发生在传统媒介工具中的“点对点”或“点对部分”式的意识形态渗透也可能会在生成式人工智能高度趋同性的作用下被放大至“点对整体”。这种个体风险的普遍化不仅仅是单个风险的叠加，甚至可能会造成系统性风险，让整个系统都发生故障或危机，[35]同时也会显著降低系统的风险抵御能力。

设想，包含错误思潮的信息一旦通过趋同化的训练被趋同化的模型所捕获，便会通过高校学生群体趋同化的应用生态中大规模、同步化地推送给成千上万的学生，这种“点对整体”式渗透的覆盖面和速度是前所未有的，可形成高校学生群体的普遍“虚假共识”。由于几乎所有学生都在与趋同化的模型交互，他们也很难在彼此间获得不同的信息来进行对冲和验证，从而极易陷入集体性的认知偏差，风险识别和抵御能力大大降低，进而可能形成群体的错误思潮。上述风险还可能会在高校学生群体对于生成式人工智能的技术依赖作用下进一步被放大，带来更加严重的意识形态危机。

（二）自主性与价值失控

生成式人工智能在与人类的互动中，表现出了其他类型媒介甚至于以往其他人工智能工具前所未有的自主交互能力，如果从参与交互实体的潜在行动能力来理解“自主性”或“主体性”，有学者指出，生成式人工智能已然展现出了一种新的人工主体性或自主性形式。[36]质言之，生成式人工智能在为用户生成和提供信息内容时，不再只是对人的指令亦步亦趋，而是具有自己的一整套工作逻辑。

然而，生成式人工智能的自主性也使其在意识形态场域中扮演了一个前所未有的角色——“非人行动者”，不同于带有明确价值立场的传统传播者，也区别于仅负责信息流通的中性渠道，生成式人工智能具备自主创作能力，能够主动地、创造性地生成关于世界、历史与价值的原创内容；但作为“非人”存在，它不具备人类的道德良知、社会责任感或对特定政治共同体的忠诚，其行为的准则主要是基于训练数据的统计相关性，以及来自特定人群的价值对齐约束。这背后实则隐含着巨大的价值失控风险：一方面，生成式人工智能技术架构的核心机制在于学习并模拟数据中的统计相关性，而单纯的数据拟合并无法为其带来价值判断能力。另一方面，正如斯坦福大学计算机科学家埃尔蒙（Stefano Ermon）所指出的：“价值观到底是什么？因为人们有不同的文化，来自全世界不同的地方，有不同的社会经济背景。”[37]特定人群对于生成式人工智能的价值对齐约束在全球不同国家社会复杂的价值鸿沟面前是乏力的。[38]例如，在西方新自由主义价值观对齐下的模型生成的内容，在全球其他国家的社会语境中很可能是与其价值观相悖的，甚至可能带来意识形态风险。有学者通过实证研究发现，使用英文交互时，ChatGPT在涉华议题上更倾向于站在西方价值观立场上呈现负面态度。[39]也有学者基于皮尤全球态度调查与世界价值观调查的测评研究表明，ChatGPT内化的文化价值观与西方主流群体高度契合，其跨文化认知呈现出显著的欧美中心主义特征。[40]简言之，不论模型的统计关联机制，还是特定人群的价值对齐约束，在宏观的全球视野下都有可能会给特定国家和社会带来价值混乱乃至失控的风险。

如前文所述，高校学生群体在认知上具有价值易塑性，其价值观念和政治态度都处于易被影响形塑的阶段。生成式人工智能在统计关联机制或特定人群价值对齐影响下生成的某些包含错误思潮的内容，在“技术中立”的掩护下极易绕过高校学生的心理防线，对学生的价值观念与政治态度产生深刻影响。

在这一过程中，学生甚至难以认识到自己接触到的是有鲜明立场偏向的信息，反而会认为自己在了解纯粹客观中立的知识。这也为更加隐秘的意识形态渗透行为提供了更加便利的可乘之机。

（三）涌现性与风险突现

涌现性（Emergence）是生成式人工智能作为智能工具的一大突出特征。“涌现”一词由学者刘易斯于1875年提出，指一种由小的部分结合成的大系统（复杂系统）形成的整体现象，即“一加一大于二”或“总体大于部分之和”。涌现性是人工智能及其传播活动的重要特征，[41]有学者从诠释学的角度指出，生成式人工智能的涌现性是训练数据、文本输入和文本输出三者之间相互关联的结果，[42]指在生成式人工智能模型的自监督学习机制下，基础模型展现出原本并非训练目标的功能的性质。

生成式人工智能的涌现性在不断推动模型功能迭代的同时，也使得开发者难以在高度复杂的模型机制中对新的模型能力进行预测，相应地，新的模型漏洞也是难以预测的。受制于模型的难以预测和解释，开发者也很难控制模型在特定任务或环境中的行为，增加了模型误用与不可控的风险，如生成有害内容、放大社会偏见、形成单点故障等。[43]有研究曾对OpennAI的GPT系列、Meta的LLaMA系列等多个生成式人工智能模型家族展开研究，发现尽管生成式人工智能的内容生成准确率在迭代中会随着规模的提升而提高，但其可靠性反而出现了开发者意料之外的下降趋势。[44]这种风险涌现也并不只见于模型的大小迭代过程，有研究发现“涌现式对齐失效”现象，即便使用少量的正常数据对已经进行过安全对齐的生成式人工智能模型进行微调，也可能无意中“解除”模型的安全防线，模型拒绝生成有害信息的能力可能会显著退化。[45]由于生成式人工智能模型新出现的漏洞和问题都是难以预测的，用户在使用生成式人工智能过程中潜在的部分意识形态风险也将可能会以“突现”形式发生，令人难以预料准备。不论是开发者、监管者的干预还是现有的制度设计相对于其都具有滞后性，难以形成有效应对。

生成式人工智能涌现性所带来的风险突现问题对于高校的意识形态工作是一种巨大隐患。突现的意识形态风险最主要的危险性在于其难以预测性与突发性，高校既有的风险处理机制可能难以形成有效风险评估和应对，进而对高校师生的认知体系造成潜移默化的形塑。而在滞后的应对措施下，价值观点容易受到影响、情绪驱动较强的学生群体则可能采取不理智的现实行动，造成不良影响和后果的升级。

三、生成式人工智能背景下高校意识形态风险的治理

生成式人工智能的技术特性造就了当前我国高校意识形态风险问题的复杂性。要有效应对这些风险，就需要从多方面着手，构建技术—制度—教育的综合治理体系，形成协同治理效能。

（一）技术治理：构建智能化风险治理体系

1. 建立多元化数据与模型生态

针对生成式人工智能的数据、模型与应用趋同可能导致的系统性风险，需以“多元化”的技术思维予以防治。在训练数据层面，生成式人工智能的开发者应建立多元化的信息生态系统，防止模型对同一数据源的依赖；同时要推动在模型训练数据中增加中华优秀传统文化、社会主义核心价值观等内容权重，确保模型输出内容的意识形态导向。在模型开发层面，建议开发或引入基于多元数据源的本土化生成式人工智能模型，减少对单一模型的依赖，预防因此引发的“算法单一文化”风险，构建具有中国特色的人工智能模型生态。目前，国产基础大模型正呈现出“百花齐放”的态势，DeepSeek系列、GLM系列等都是本土生成式人工智能模型的杰出代表。高校在部署和调试生成式人工智能模型时，可在充分调研的基础上选择更符合主流意识形态导向的基础模型，并结合校内的实际教育需求对其进行更具针对性的训练调试。

2. 开发价值审计与对齐技术

针对生成式人工智能自主性带来的价值失控风险，构建一个集监测、反馈、纠偏于一体的闭环治理体系。首先，应当面向高校主要应用或部署的生成式人工智能系统建立全面、定制化的价值审计体系与系统，实现意识形态风险的早期识别与预警。目前，国内部分研究机构与人工智能企业已开展了一些探索性工作，开发了一系列人工智能安全评测系统，例如清华大学建设的SafetyBench、上海人工智能实验室研发的OpenCompass司南评测体系。但整体而言，这些评测系统对意识形态风险，尤其是面向高校情境的考虑还较为欠缺。同时，为确保审计体系的精准与有效，应当构建师生共同参与的内容标注与反馈机制，不断优化审计体系与系统的准确性和敏感性，使其更贴合高校的实际需求。除此之外，在技术层面实现价值纠偏与引导，还需要跨学科的深度协作。积极联动技术专家与社会科学、教育学、马克思主义理论等领域的专家，共同开发面向高校场景的价值审计体系与对齐技术，将正确的价值导向内嵌于技术内核，实现价值纠偏与价值引导。

3. 构建涌现风险预警与响应系统

针对生成式人工智能涌现性带来的风险突现问题，建议对部署在高校的模型工具展开持续高效的“红队测试”，对生成式人工智能模型可能涌现和叠加的漏洞风险进行测试排查，[48]做到防微杜渐。OpenAI 曾在 GPT-4 发布前通过“红队测试”发现了与该模型外部知识源结合后可能带来的物理安全风险，促使 OpenAI 在发布前进一步强化了安全过滤器，并限制了某些高敏感场景下的模型输出能力。[49]高校可参考业界“红队测试”经典案例，面向高校意识形态安全语境开展针对性测试。同时，高校应当建立“熔断”与应急响应机制，确保在风险突现时，可对人工智能的风险行为进行熔断终止，并能够迅速启动应急响应机制，避免造成更大的危机。

（二）制度层面：完善多层次治理框架

1. 完善和落实高校意识形态工作责任制

《中共中央关于制定国民经济和社会发展第十五个五年规划的建议》提出，“坚持马克思主义在意识形态领域的指导地位，植根博大精深的中华文明，顺应信息技术发展潮流，发展具有强大思想引领力、精神凝聚力、价值感召力、国际影响力的新时代中国特色社会主义文化，扎实推进文化强国建设。”[49]以此为遵循，面对生成式人工智能应用所引发的意识形态风险新态势，高校亟须通过制度完善来巩固和落实意识形态工作责任制。具体而言，高校可在纵向设计上完善多级主体责任体系，在横向设计上建立多部门监管的分工协作机制，通过横纵双向的制度设计，为生成式人工智能时代高校的意识形态工作提供制度保障。

2. 建立高校人工智能意识形态安全影响评估机制

高校可以借鉴金融和环保领域的影响评估制度，对部署和使用的生成式人工智能工具进行前置审查评估，做到防患于未然。高校可成立由技术专家、思政教师、法学专家、学生代表组成的人工智能意识形态安全影响评估委员会，在正式采购、部署或向学生推广生成式人工智能工具前，向该委员会提交人工智能意识形态安全影响评估报告。报告需详细说明该模型的训练数据来源、算法可能存在的偏见、对意识形态安全的潜在影响、数据隐私保护措施等。委员会根据报告进行听证和审议，通过后方可实施采购和部署。目前，国内已有部分高校开启了相关探索：例如，清华大学成立了科技伦理委员会，下设人工智能分委员会，通过推动风险治理体制机制建设、人工智能伦理审查和监管、教育和宣传等工作，增强学校应对人工智能意识形态风险的能力。[49]

3. 完善高校生成式人工智能使用规范

建议高校制定专门针对生成式人工智能的校园使用管理办法，明确师生在学术研究、课堂教学、日常交流中使用生成式人工智能工具的边界和规范。建立“人工智能生成内容标注”制度，在教学、科研、作业等所有正式场景中，要求使用人工智能生成的内容须明确标注“人工智能辅助生成”，并对不宜使用人工智能生成内容的场景作出明确限制。2025 年，教育部教师队伍建设专家指导委员会发布了《教师生成式人工智能应用指引（第一版）》，[50]对人工智能在教育中的使用进行了更加明确的规范；2026 年 4 月，教育部等五部门印发《“人工智能 + 教育”行动计划》，为人工智能在不同学段与场景的应用规范框定了总体要求[51]。据多家媒体报道，目前清华大学、[52]复旦大学、[53]上海交通大学、[54]北京邮电大学[55]等高校也都已先后出台了人工智能教育科研应用规范或标准。在未来，这些规范需要伴随生成式人工智能的发展不断调整更新。

（三）教育层面：提升师生智能素养和批判思维

1. 开展生成式人工智能素养教育

建议高校结合学生对于生成式人工智能的技术依赖，有针对性地开设专门的生成式人工智能素养课程，并将人工智能素养教育纳入通识教育体系，帮助学生了解生成式人工智能的工作原理、技术局限和潜在风险，提升学生对生成式人工智能技术的应用与批判能力。据报道，截至 2025 年 10 月，北京市已有 38 所高校开设了旨在加强学生人工智能素养训练的通识课程，[56]代表着高校生成式人工智能素养教育已开始进行初步探索。

2. 强化正确技术观教育引导

建议高校开设系统性的技术观教育课程，探讨技术与社会、政治、文化的共生关系。通过课程向学生澄清“技术中立论”的潜在局限性，通过引入多元化生成式人工智能的潜在风险研判、案例等，开阔学生对前沿技术与意识形态的关系认识，让学生深刻理解“技术亦可成为价值的潜在载体”。

综上所述，生成式人工智能的发展与普及在给广大高校师生带来便利的同时，也为高校的意识形态风险形成了新的挑战。生成式人工智能背景下高校意识形态风险的治理，既需要技术手段的支撑，也需要制度机制的保障，还需要教育引导的浸润。三者相辅相成、缺一不可。高校应当着力构建“技术赋能、制度保障、教育引导、协同共治”的治理模式，有效应对生成式人工智能带来的意识形态风险，维护高校意识形态安全，为新时代高校意识形态安全建设提供有力支撑。

参考文献：

①习近平：《论党的宣传思想工作》，中央文献出版社 2020 年版，第 31 页。

②㊽新华社：《中共中央关于制定国民经济和社会发展第十五个五年规划的建议》，中华人民共和国中央人民政府网站，https://www.gov.cn/zhengce/202510/content_7046050.htm，2025 年 10 月 28 日。

③王浩业：《新时代高校意识形态工作机制探究》，《思想教育研究》2024 年第 1 期。

④刘立伟、谢晓娟：《新时代高校意识形态工作研究》，《学校党建与思想教育》2023 年第 3 期。

⑤贺伊娜：《网络时代高校意识形态工作的特征与实践进路》，《学校党建与思想教育》2025 年第 4 期。

⑥张树辉、李镕成、张润泽：《人工智能时代高校意识形态工作的现实挑战与范式革新》，《中国社会科学院大学学报》2025 年第 6 期。

⑦杨晓彤：《生成式人工智能的意识形态隐喻及其具象化风险应对》，《马克思主义研究》2025 年第 9 期。

⑧刘天元、晏静露：《智能变革中的不安：青年群体 AI 焦虑的形成机制及其影响》，《中国青年研究》2025 年第 2 期。

⑨朱秀凌：《手机技术反哺、亲子沟通与父母教养方式——基于技术接受与使用整合模型的分析》，《新闻大学》2018 年第 4 期。

⑩李瑞奇、李高磊：《生成式人工智能的意识形态风险：出场、样态与治理》，《当代世界与社会主义》2025 年第 2 期。

⑪祝黄河、凌学武：《生成式人工智能意识形态风险的样态表征、逻辑理路与治理策略》，《江西师范大学学报（哲学社会科学版）》2025 年第 4 期。

⑫谢成宇、徐荧松：《生成式人工智能时代意识形态风险的现实样态、生成逻辑及治理路径》，《思想教育研究》2025 年第 8 期。

⑬刘成、莫生叶：《生成式人工智能应用中的意识形态安全边界厘清、风险监测及规制理路——基于 DeepSeek、Manus、ChatGPT、Sora 的思考》，《重庆大学学报（社会科学版）》2025 年第 4 期。

⑭孔德臣、侯勇：《生成式人工智能的意识形态治理：契机、风险与应对——从 ChatGPT 到 Sora》，《探索》2024 年第 4 期。

⑮刘文郡：《生成式人工智能对意识形态的挑战及其调适路径》，《马克思主义与现实》2025 年第 4 期。

⑯魏屹东、李煜慧：《生成式人工智能引发的意识形态风险及其应对》，《理论探索》2025 年第 2 期。

⑰帅建强、韩源：《浅析生成式人工智能意识形态风险样态、生成诱因及其治理逻辑》，《西南民族大学学报（人文社会科学版）》2024 年第 3 期。

⑱孙鹏、甘翔：《人工智能视域下高校意识形态工作的挑战与对策研究》，《大学教育》2025 年第 15 期。

⑲路坤皓、郝文斌：《生成式人工智能引发高校网络意识形态风险：样态、诱因与纾解》，《陕西师范大学学报（哲学社会科学版）》2025 年第 4 期。

⑳韩子勇、高佳彬：《“意识形态”概念流变考梳》，《文艺理论与批评》2020 年第 5 期。

㉑赵敦华：《“意识形态”概念的多重描述定义——再论马克思恩格斯的意识形态批判理论》，《社会科学战线》2014 年第 7 期。

㉒杨章文：《“观念的秩序”：“意识形态”概念的分歧、嬗变与马克思主义重构》，《中国地质大学学报（社会科学版）》2020 年第 5 期。

㉓俞吾金：《意识形态论》，人民出版社 2009 年版，第 68、129 页。

㉔龚锦涛：《新时代中国共产党意识形态工作的理论创新与实践拓展》，《新疆社会科学》2020 年第 3 期。

㉕李海林：《论意识形态的层次性内涵、载体及功能》，《宁夏大学学报（社会科学版）》2025 年第 3 期。

㉖王里、朱旗：《高校意识形态话语权：内涵、挑战与对策》，《江苏高教》2017 年第 1 期。

㉗〔美〕B·J·沃兹沃思：《皮亚杰的认知发展理论》，周镐译，华中师范大学出版社 1986 年版，第 97–103 页。

㉘〔美〕E. 埃里克松：《同一性：青少年与危机》，孙名之译，中央编译出版社 2015 年版，第 307–324 页。

㉙ B. Pawlowska, M. Zygo, et al.: Prevalence of Internet addiction and risk of developing addiction as exemplified by a group of Polish adolescents from urban and rural areas, *Annals of Agricultural and Environmental Medicine*, 2015, 22(1), pp129–136.

㉚ Jiang, L., Chai, Y., Li, M., Liu, M., Fok, R., Dziri, N., et al.: *Artificial hivemind: The open-ended homogeneity of language models (and beyond)*, arXiv preprint arXiv:2510.22954, 2025.

㉛ Statcounter: AI Chatbot Market Share Worldwide, Statcounter 网站：https://gs.statcounter.com/ai-chatbot-market-share

㉜ A. R. Doshi, O. P. Hauser, et al.: Generative AI enhances individual creativity but reduces the collective diversity of novel content, *Science Advances*, 2024, 10(28), eadn5290.

㉝ E. Zhou, D. Lee, et al.: Generative artificial intelligence, human creativity, and art, *PNAS Nexus*, 2024, 3(3), p052.

㉞ Q. Hao, F. Xu, Y. Li, et al.: Artificial intelligence tools expand scientists’ impact but contract science’s focus, *Nature*, 2026,

㉟ G. Kaufman & K. Scott: What is systemic risk, and do bank regulators retard or contribute to it?, *The Independent Review*, 2003(3).

㊱殷杰：《生成式人工智能的主体性问题》，《中国社会科学》2024 年第 8 期。

㊲〔美〕B. 克里斯汀：《人机对齐——如何让人工智能学习人类价值观》，唐璐译，湖南科学技术出版社 2023 年版，第 245–246 页。

㊳曾雄：《人工智能大模型价值对齐的现状考察、问题检视与规范进路》，《电子商务》2025 年第 2 期。

㊴党明辉、凌兴福、丁朋娜：《生成式智能媒体对涉华议题的媒介记忆——以 ChatGPT 为例》，《当代传播》2023 年第 5 期。

㊵ J. Durmus, K. Nguyen, T. I. Liao, N. Schiefer, A. Askell, A. Bakhtin, et al.: *Towards measuring the representation of subjective global opinions in language models*, arXiv preprint arXiv:2306.16388, 2023.

㊶彭兰：《智能与涌现：智能传播时代的新媒介、新关系、新生存》，电子工业出版社 2023 年版，第 61–64 页。

㊷刘伟伟：《诠释学视域下大语言模型的“涌现性”问题研究》，《逻辑、智能与哲学》2025 年第 1 期。

㊸ R. Bommasani: On the opportunities and risks of foundation models, arXiv preprint arXiv:2108.07258, 2021.

㊹ L. Zhou, W. Schellaert, F. Mart í nez-Plumed, et al.: Larger and more instructable language models become less reliable, *Nature*, 2024, 634(8032), pp61-68.

㊺ Betley, J., Warncke, N., Sztyber-Betley, A., Tan, D., Bao, X., Soto, M., Srivastava, M., Labenz, N., & Evans, O: Training large language models on narrow tasks can lead to broad misalignment, *Nature*, 2025, 649(8097), 584-589.

㊻包泽苋、钱铁云：《大模型红队测试研究综述》，《计算机科学》2025 年第 1 期。

㊼《AI 比核武器还危险？ ChatGPT 为此建立了一支“红队”》，凤凰网，https://tech.ifeng.com/c/8Oyiu1skygz，2023 年 4 月 14 日。

㊾《清华大学第一届科技伦理委员会第二次全体会议暨 2024 年度会议举行》，清华大学网站，https://www.tsinghua.edu.cn/info/1177/112240.htm，2024 年 6 月 18 日。

㊿《政策引领教育 AI 规范化 教师专属工具“飞象老师”落地赋能教学提质》，新华网，http://www.xinhuanet.com/tech/20251201/f29d2a744c32403e83be7c229fc86663/c.html，2025 年 12 月 1 日。

(51)《教育部等五部门关于印发〈“人工智能 + 教育”行动计划〉的通知》，中华人民共和国教育部，http://www.moe.gov.cn/srcsite/A16/s3342/202604/t20260410_1433240.html，2026 年 4 月 10 日。

(52)《严禁用 AI 实施学术不端！清华大学发布首个 AI 教育应用指导规范》，清华大学网站，https://www.tsinghua.edu.cn/info/1182/122783.htm，2025 年 11 月 27 日。

(53)《复旦发布人工智能教学应用指引，明确 AI 使用边界、评价维度等》，澎湃新闻，https://m.thepaper.cn/newsDetail_forward_32367274，2026 年 1 月 23 日。

(54)《上海交大发布 AI 使用规范》，上观新闻：https://www.shobserver.com/staticsg/res/html/web/newsDetail.html?id=870379&sid=11，2025 年 3 月 5 日。

(55)《高校纷纷为 AI 工具使用“立规矩”有高校通告“作业用 AI 生成全算零分”》，财联社，https://www.cls.cn/detail/1954893，2025 年 2 月 26 日。

(56)《38 所高校开设人工智能通识课》，北青网，http://epaper.ynet.com/html/2025-10/31/content_304024.htm，2025 年 10 月 31 日。

（作者陈慧敏系清华大学新闻与传播学院副教授、博士生导师；刘钊宁系清华大学新闻与传播学院博士研究生；庄臣系清华大学新闻与传播学院教师、党委办公室主任）

【责任编辑：刘璐】