生成式人工智能驱动下高校意识形态安全的新挑战

谢　媛[1]，龙　偲[1]，陈华榕[2]
1 衡阳师范学院马克思主义学院　湖南　衡阳　421002；
2 衡阳师范学院经济与管理学院　湖南　衡阳　421002

【摘要】针对生成式人工智能给高校意识形态领域带来的认知幻象风险和价值观冲突风险，本文结合问卷调查与文献分析，提出以责权适配、技术监管与协同合作构成的“双向赋能”路径，以优化主流意识形态话语的传播效能。研究结果表明，该路径有助于强化高校意识形态风险的主动防控与价值引导，从而为维护主流意识形态安全、落实立德树人使命提供理论参考与实践依据。

【关键词】生成式人工智能；双向赋能；高校意识形态安全
【中图分类号】G641；TP18　　【文献标识码】A　　DOI：10.16009/j.issn.1009-5624.2026.07.055

0　引言

加快发展新一代人工智能（artificial intelligence，AI），是关系我国能否抓住新一轮科技革命与产业变革机遇的战略问题[1]。AI 技术的深度应用正深刻重塑着高校的知识生产、信息传播与话语建构方式，既为意识形态工作带来了智能化生产、精准化适配、实时性反馈、技术化监管等机遇，又引发了供给结构性失衡、价值偏离、传播失序、主体性弱化、治理迟滞等风险与挑战[2]。这不仅构成了主流意识形态话语传播的现实境遇，还为其传播范式转型提供了重要载体[3]。这些由技术衍生的风险正持续地、系统性地冲击意识形态安全防线[2]，使得 AI 安全成为全球治理与国家现代化治理体系构建的关键议题[4]。高校作为意识形态工作的前沿阵地，肩负为党育人、为国育才的重要使命。基于此，本文以高校大学生为研究对象，结合对千名学生开展的问卷调查与相关文献分析，探索生成式 AI 驱动下高校意识形态领域面临的新挑战与可行的新路径。

1　传播失控：数据偏倚与认知幻象风险

生成式 AI 的内容生产高度依赖训练数据与算法模型。其技术黑箱特性与低门槛传播优势，极易引发传播失控问题，对高校意识形态安全构成挑战。

（1）数据偏倚风险。AI 大模型的训练依赖于包含结构性偏见的历史数据，这会固化并放大既有偏见，导致智能教育决策偏误[5]。具体表现为：其一，样本代表性偏差。训练数据覆盖不全，决策过程不透明，且可能在训练阶段遭受模型投毒等攻击[6]，从而易输出片面观点误导用户。其二，选择与幸存者偏差。数据倾向于抽取热点样本，生成内容易失之片面，制造虚假共识。由于数据偏见的存在，在算法运行中可能会放大这种偏见。例如，东西方文化建立在不同的哲学传统之上，在数据隐私等关键问题上可能存在重大且无法解决的价值差[7]。其三，因果与伪相关偏差。算法可能将偶然关联解读为必然规律，若被恶意主体包装为“科学依据”，将误导公共决策或学术研究。

（2）生成内容幻象风险。生成式 AI（如 ChatGPT）常因其基于概率预测的生成机制，产生事实错误或推理谬误，即“AI 幻觉”。这种“无意识失真”表现为生成文本语法流畅但事实错误，或逻辑自洽但观点偏颇。具体可分为两类：其一，真实性幻象。由“算法幻觉”或深度伪造技术产生的弥散性“伪真相”，会消解主流意识形态所依赖的“事实真相”[8]。由于训练数据碎片化、知识图谱不完善，模型可能编造不存在的文献或判例，此类内容若被学生用于学术作弊，或被恶意主体用以伪造证据，将严重损害学术诚信与社会信任。其二，价值导向性幻象。在数据偏倚的基础上，模型会生成符合偏差倾向的价值判断，从而隐性消解主流意识形态。研究数据显示，不同模型的幻觉率存在显著差异，如 DeepSeek-V3 模型的幻觉率约为 3.9%，而 DeepSeekR1 则高达 14.3%。相比之下，OpenAI 的 GPT-4o 约为 1.5%，GPT-o1 约为 2.4%[9]，这提示了技术路线与风险控制水平的影响。

（3）人为驱动讹见风险。此风险指恶意主体有意利用数据偏倚与内容幻象等技术缺陷，定向生成与传播误导性内容，以实现意识形态渗透或认知操控。其实现路径主要包括：其一，幻象内容的二次加工与传播。攻击者可通过数据投毒等手段操控训练数据，诱导模型在特定触发条件下输出预设的敏感信息或有害内容[6]。更有甚者，将模型生成的价值导向幻象内容进行拼接，包装成“权威解读”进行二次传播，在大学生群体中扩散，加剧了高校意识形态安全的博弈风险。其二，文化价值的定向植入与冲击。训练数据中隐含的文化偏向会通过生成内容实现隐性传播，对高校学生的价值认同形成潜移默化的长期冲击。AI 的这种新型“可控性”问题，已难以通过传统的风险治理框架有效应对[10]。

2　话语失智：加剧价值博弈冲突风险

在全球化背景下，AI 生成内容可能传播并固化既有文化偏见，催生“话语失智”现象，进而加剧不同主体间的价值博弈与意识形态冲突。

（1）本土文化安全风险。AI 是人创造的，人是主体，机器人是客体[11]。从基础研究到实际运用，技术开发主

基金项目：湖南省高校思想政治工作研究项目“类 ChatGPT 人工智能冲击下我国大学生安全教育研究”（23C21）。
作者简介：谢媛（1989—），女，湖南衡阳人，博士，讲师，研究方向：马克思主义理论。

体的文化背景易于生成并输出有利于其自身文化立场的话语体系。具体风险体现在两方面：其一，工具诱发的隐匿性文化输入。AI 技术打破了传统话语传播的时空限制，成为特定意识形态隐蔽且高效的渗透载体。例如，由 OpenAI 公司研发的 ChatGPT，其训练语料以英语为主，训练数据来源于互联网，不可避免地内嵌了西方文化的价值观和偏见，其平台主导地位可能带来长期的文化渗透。其二，教育互动的人文博弈。调查显示（图 1），75%的学生在查询知识时会经常优先使用 AI；59.2%的学生认为 AI 未来可能替代教师的部分基础工作，而坚定认为完全不会替代教师的仅占 16.8%。这反映出 AI 在教育场景中已被深度接纳。虽然 AI 目前难以复制教师所传递的情感关怀与本土人文温暖，但正如语言学家乔姆斯基所言，其应用本质是“高科技抄袭”[12]，若过度依赖，则教育中蕴含的深层文化价值与批判性思维仍有被工具理性所消解的可能。

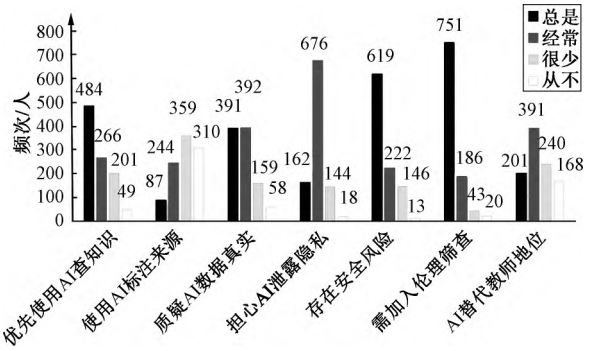


图 1　类 ChatGPT AI 工具对大学生影响调查

（2）社会价值体系的冲击。在自媒体时代，海量且良莠不齐的网络信息构成了 AI 训练数据的重要来源。一方面，基于此形成的话语去中心化特征愈发凸显，普通群体的话语表达权被极大释放，同时也带来了价值导向的碎片化。另一方面，广泛的智能推送极易为大学生构筑“信息茧房”，加速了算法编织的“伪真相”更广泛、更超速地离散化传播[3]，使得高校意识形态教育的话语阵地被不断侵蚀。AI 不仅重塑了信息流通与认知结构，还在无声之中编织出新的权力格局与价值秩序[13]。这种信息博弈，进一步印证了价值观冲击的现实性。大学生正处于拔节孕穗期，心智尚未完全成熟，批判性思维与辨别能力不足，极易在此环境中被诱导并固化价值偏见。

（3）公共伦理的博弈失衡。人类伦理规范根植于长期的情感体验、社会互动与文化传承，而 AI 仅依赖数据的机械映射，缺乏内在的道德规训，极易引发伦理安全风险。这突出表现为：①隐私泄露风险。调研显示（图 1），83.8%的大学生担心 AI 泄露个人隐私；84.1%认为 AI 存在安全风险。这揭示出，若对话数据被不恰当的用于商业目的，学生的隐私保护与技术伦理将面临双重失范。②诚信风险。问卷数据（图 1）表明：学生使用 AI 完成学术任务时，“从不标注”来源的占 31%，“偶尔标注”的占 35.9%，而“每次都标注”的仅 8.7%。这一行为模式背后反映出伦理认知的普遍薄弱。值得关注的是，学生对于建立规范的诉求强烈，75.1%的学生支持在 AI 中“加入伦理筛查”。这为智能时代高校伦理规范的针对性建设提供了重要的现实依据与民意基础。

3　双向赋能：高校意识形态安全的新路径

从全球范围来看，AI 已步入技术发展的“关键转折期”与 AI 治理的“重要窗口期”[14]。AI 冲击下高校意识形态认知幻象和价值冲突风险加剧，可进一步归因于主体责任模糊、监管标准不一、技术拦截滞后、个体意识不足等因素。因此，有必要在当下探索高校意识形态安全的新路径。

（1）责权适配，意识先行。我国在《全球人工智能治理倡议》中提出了“智能向善”的理念，为应对风险提供了重要指引[15]。然而，在具体规制层面，如国务院 2025 年度立法工作计划仅强调“推进 AI 健康发展立法工作”，我国 AI 专项立法规制体系尚付阙如，相关顶层设计与专项立法体系正处于加速完善过程中，但在具体规制层面仍有进一步细化的空间[16]。在此背景下，高校意识形态安全治理的首要任务是厘清“谁负责、如何管”这一核心，通过伦理引导与法律保障的双向赋能来适配权责。一方面，应强化法律保障与外部约束。亟待建立 AI 意识形态风险问责机制，明确 AI 使用引发意识形态偏差的责任主体与处罚标准，杜绝权责真空。建立算法黑箱抽查与动态退出机制，对违规工具采取暂停校内使用权限、纳入采购黑名单等措施，保障 AI 技术在高校的安全、合规、向善应用。另一方面，须深化伦理引导与内在自觉。以伦理教育为抓手，针对师生开展意识形态审核培训与价值观引导，助推其理性看待 AI、摒弃盲目依赖。伦理引导与法律保障双向发力，以内促自觉、以外强约束，确保内容合法合德，守护高校意识形态安全。

（2）技术优化，强化监管。类 ChatGPT 工具的快速迭代与隐蔽化传播，使得依赖“事后应对”的传统风险防控模式日益被动。2024 年，我国《“数据要素×”三年行动计划（2024—2026）》明确提出“鼓励依托市场化机制开发文化大模型”“建设高质量语料库和基础科学数据集”等要求[17]。在此背景下，主流意识形态传播必须坚持“以我为主，为我所用”的原则，积极引导技术向善，遏制资本在文化市场的无序扩张。为此，应推动技术迭代与治理向善双向赋能，实现意识形态风险防控的主动预判与精准防控。在技术层面，须着力破解风险识别难题，为 AI 应用划定意识形态红线，确保其在本土文化、国家制度等内容中坚守中国立场、凸显中国视角。在监管层面，则应强化对高频场景的重点监管，并依托学术行为等动态数据进行常态化追踪与风险预警。同时，建立与企业的联动反馈机制，允许用户就 AI 内容偏差、隐私保护等问题提出优化诉求，推动模型迭代或信息修正，从而在保障监管效能的同时，为技术创新预留合理空间。

（3）协同合作，统筹创新。通过协同合作与创新治理的双向赋能，着力破解当前高校内部治理割裂、校地协同脱节的困境。一是建立高校类 AI 意识形态安全治理中心，整合资源形成风险识别、技术拦截、教育引导的闭环管理。创新开发红色 AI 助手，将党史、思政知识融入 AI 交互。依托技术创新筑牢意识形态话语主阵地，借助 AI 算法的精准分发优势，推动主流意识形态内容的广泛传播，有效破解“信息茧房”效应。二是构建“校企地”协同机制，整合高校的人才资源、政府的政策资金及企业的技术支撑，联合研发与社会主义核心价值观深度契合的优化工具，从技术源头降低意识形态风险，最终实现以先进技术反哺立德树人的根本任务。

4　结语

本文系统阐述了生成式 AI 对高校意识形态安全的多维冲击，揭示了其在传播失控、话语失序与治理失范等层面形成的复合风险机理，进而从“双向赋能”的视角提出了涵盖责权适配、技术监管与协同创新的综合治理路径。研究成果可为高校有效应对智能技术挑战、巩固主流意识形态阵地提供理论参照与实践启示。然而，本研究仍存在一定局限：一方面，结论主要基于问卷调研，未来可结合多源数据与长期观察，增强实证支撑；另一方面，所提治理路径在实操层面的效能有待进一步检验。未来，可从以下方向深化研究：一是构建动态风险评估框架，实现智能监测与主动干预；二是研发适配教育场景的技术反制工具，提升风险应对的精准性与有效性；三是探索跨区域、跨领域的协同治理机制，推动形成更具韧性的意识形态安全体系。

【参考文献】

[1] 新华社.习近平在中共中央政治局第二十次集体学习时强调坚持自立自强突出应用导向推动人工智能健康有序发展[J].中国教育网络，2025(4)：1.

[2] 高盛楠，张远航.人工智能时代主流意识形态供给体系重构：范式变革、风险挑战与系统优化[J].烟台大学学报(哲学社会科学版)，2026，39(1)：23-31.

[3] 苏洁.生成式人工智能赋能主流意识形态话语传播的逻辑进路[J].马克思主义理论学科研究，2025，11(11)：99-107.

[4] 吴世忠.统筹发展和安全积极应对人工智能治理新挑战[J].中国网信，2025(9)：28-32.

[5] 宋萑，林敏.ChatGPT/生成式人工智能时代下教师的工作变革：机遇、挑战与应对[J].华东师范大学学报(教育科学版)，2023，41(7)：78-90.

[6] 陈永伟.从规模定律到规模经济：DeepSeek 的创新、机遇与挑战[J].山东大学学报(哲学社会科学版)，2025(5)：140-151.

[7] HOROWITZ M C，ALLEN G C，KANIA E B，et al. Strategic competition in an era of artificial intelligence[R/OL].(2018-07-01)[2026-01-05].https://www.cnas.org/publications/reports/strategic-competition-in-an-era-of-artificial-intelligence.

[8] 胡国胜，何美蓉.生成式人工智能嵌入高校思想政治教育的变革逻辑、问题检视与调适范式[J].教育评论，2025(6)：54-66.

[9] 张宁.生成式人工智能数据安全风险及其防控体系研究[J].公安学研究，2025，8(2)：83-104，124.

[10] 陈小平.人工智能伦理治理：一种新型问题的底层逻辑和创新探索[J].生命科学，2022，34(8)：983-989.

[11] 何星亮.智能革命与文明变迁：人类学的视角[J].中南民族大学学报(人文社会科学版)，2019，39(4)：75-80.

[12] OPEN C. Noam Chomsky on ChatGPT：it's "basically high-tech plagiarism" and "a way of avoiding learning"[EB/OL].(2023-02-09)[2025-07-15].https://www.openculture.com/2023/02/noam-chomsky-on-chatgpt.html.

[13] 晏青，陈豪辉.作为意识形态的 AI：逻辑、风险与调适[J].未来传播，2025，32(6)：2-14.

[14] 张欣，宋雨鑫.全球人工智能治理的格局、特征与趋势洞察[J].数字法治，2024(1)：199-212.

[15] 中国网信网.全球人工智能治理倡议[EB/OL](2023-10-18)[2025-12-29].https://www.cac.gov.cn/2023-10/18/c_1699291032884978.htm.

[16] 袁秀挺，严驰.人工智能激励型立法审思：以激励规制理论为视角[J].中国海商法研究，2025，36(4)：32-40.

[17] 国家数据局等 17 部门联合印发《“数据要素×”三年行动计划(2024—2026 年)》全文[J].自动化博览，2024，41(1)：2.